



中国科学院大学
University of Chinese Academy of Sciences

硕士学位论文

终端自适应的在线定位技术与应用

作者姓名：夏俊

指导教师：刘军发 副研究员

中国科学院计算技术研究所

学位类别：工程硕士

学科专业：软件工程

培养单位：中国科学院计算技术研究所

2018 年 6 月

**Device Adaptive Online Localization Method and
Application**

**A thesis submitted to
University of Chinese Academy of Sciences
in partial fulfillment of the requirement
for the degree of
Master of Engineering
in
Software Engineering**

By

Jun Xia

Supervisor: Professor Junfa Liu

**Institute of Computing Technology
Chinese Academy of Sciences**

June 2018

中国科学院大学
研究生学位论文原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明或致谢。

作者签名：

日 期：

中国科学院大学
学位论文授权使用声明

本人完全了解并同意遵守中国科学院有关保存和使用学位论文的规定，即中国科学院有权保留送交学位论文的副本，允许该论文被查阅，可以按照学术研究公开原则和保护知识产权的原则公布该论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存、汇编本学位论文。

涉密及延迟公开的学位论文在解密或延迟期后适用本声明。

作者签名：

日 期：

导师签名：

日 期：

摘 要

随着物联网(Internet of things, IoT)时代的到来,以及各类新型智能移动设备的出现,基于位置感知的应用呈爆发性增长,其中定位技术起到了越来越重要的作用。由于现有的 GPS 等卫星定位技术不适用于高动态性复杂室内场景,人们开始研究各类针对室内场景的定位技术。到目前为止,出现的各类定位技术都有一些应用局限。常见的定位技术如红外定位、超声波定位、UWB 定位、RFID 定位等,或者需要专门的硬件设备,或者部署复杂、定位局限性高,难以进行大规模的推广应用。随着国内大力推进智慧城市、智慧商业环境建设,WiFi 和蓝牙作为智能手机支持的两种基本的无线设备,在国内大多城市广泛普及,给基于 WLAN、蓝牙的低成本室内定位技术提供了丰富的无线信号资源。不论是基于 WLAN 或是低功耗蓝牙的室内定位技术,大部分的应用主要依赖于位置指纹定位算法。位置指纹定位算法具有定位精度较高、适用性广、定位成本较低的优点。但是传统的位置指纹定位算法还存在数据标记难、模型时效性差和设备差异性大等问题。这些问题一方面极大增加了训练阶段的工作量,另一方面严重影响了模型的定位精度,最终制约了位置指纹算法的应用。

针对上述问题,本文基于极速学习机模型(Extreme Learning Machine, ELM)提出半监督增量式极速学习机算法。通过半监督学习解决数据标记难问题,通过在线增量式学习方式解决模型时效性问题和设备差异性问题,从而使模型具有终端自适应能力,有效解决上述问题。全文主要工作可总结如下:

1) 首先总结归纳目前常见的室内定位技术,重点对目前位置指纹定位方法面临的终端差异问题进行调研和分析,对目前市面上多款手机在信号扫描上差异性进行实验验证。

2) 提出一种终端自适应的在线定位方法。该方法基于半监督增量式极速学习机算法,终端首先获得初始定位模型,然后在定位服务阶段,可以利用终端自身实时采集的无标记数据进行在线更新,从而有效解决数据标记难问题、模型时效性问题和设备差异性问题。并通过实验验证该方法的有效性。

3) 设计并实现一种低功耗蓝牙室内定位系统。该系统包括指纹采集客户端、位置服务云平台 and 在线定位 SDK。用户先在位置服务云平台注册定位场景信息,

然后使用指纹采集客户端采集场景指纹，最后在自己应用中集成在线定位 SDK 即可实现室内定位服务。系统测试结果表明本系统具有很好的实用性。

关键词：室内定位，终端自适应，在线学习，极速学习机

Abstract

With the advent of the Internet of Things, and the development of various new smart mobile devices, there has been explosive growth in location-aware applications where locating technology is playing a more and more important role. People began to research kinds of indoor localization methods because existing satellite positioning technology such as GPS is not applicable for indoor high dynamic environment. But, so far, there has not appeared an indoor localization method which could meet the requirement of LBS(Location Based Services, LBS) application with Low-Cost and High-Precision. The existing indoor localization technologies such as infrared localization, ultrasonic localization, UWB(Ultra-Wideband, UWB) localization and RFID(Radio Frequency Identification, RFID) localization are all difficult to widely apply because they are limited by requiring either specified hardware or complicated employment. Now, the WLAN(Wireless Local Area Networks, WLAN) or BLE(Bluetooth Low Energy, BLE) based wireless indoor localization method brings solution for the problem. As our country energetically builds the Smart City, WiFi and BLE are widely used in most cities which offers a great chance for low-cost indoor localization method.

The WLAN and BLE based wireless indoor localization always depend on fingerprint localization method which has good performance and extensive applicability. However, in practical applications, there are three problems in existing fingerprint based methods or systems: Firstly, the localization error caused by device variance is a severe problem. Secondly, the wireless data is changing as the time passes, which leads to the reduction of the prediction accuracy. Thirdly, traditional fingerprint based methods or system cannot avoid the dependency on a large amount of labeled data to keep effective positioning performance, which usually involves a great deal of manual effort and long training time on offline phase. To solve these problems, we proposed an incremental indoor localization method for device diversity issues, which

keeps real-time update by training unlabeled data collected in localization. The main work of the thesis can be summarized as three following parts:

- 1) We will summarize the current common indoor localization technologies, especially investigate and analyze the device differences faced by the traditional fingerprint indoor localization. And then, the device diversity will be verified by experiments.
- 2) We propose a device adaptive online localization method basing on semi-supervised online sequential ELM algorithm. In the process of locating, the terminal will get initial localization model in offline phrase, and then, the model can updated itself by the unlabeled data real-time collected. Comparative experiments show that this method can dramatically reduce labeled calibration samples, and have good advantage of timeliness compared with traditional indoor localization method.
- 3) We design and realize a BLE indoor localization system, which includes fingerprint acquisition client, location service cloud platform and online location SDK. The user needs to register the location place information in the cloud platform, then uses the fingerprint acquisition client to collect the rssi data, and finally realize the indoor localization service in the user's application by integrating the online location SDK. The test results show that the system has good practicability.

Key Words: indoor localization, device adaptive, online learning, Extreme Learning Machine

目 录

第 1 章 引言	1
1.1 研究背景与意义	1
1.2 室内定位技术与研究现状	2
1.2.1 常见室内定位技术研究现状	2
1.2.2 终端差异性的室内定位技术研究现状	5
1.3 本文的研究重点及贡献	6
1.4 本文的组织结构	7
第 2 章 室内无线定位技术	9
2.1 室内无线信号传播特点	9
2.2 室内无线定位技术介绍	10
2.2.1 基于 TOA 的室内定位技术	10
2.2.2 基于 TDOA 的室内定位技术	11
2.2.3 基于 AOA 的室内定位技术	13
2.2.4 基于 RSSI 的室内定位技术	13
2.3 位置指纹定位方法	15
2.3.1 位置指纹定位方法原理	15
2.3.2 典型室内指纹定位匹配算法	16
2.3.3 指纹定位方法的优缺点	20
2.4 本章小结	25
第 3 章 终端自适应的在线定位算法研究	27
3.1 机器学习方法概述	27
3.1.1 机器学习概念	27
3.1.2 机器学习算法的常见形式	28
3.1.3 离线学习与在线学习	31
3.2 极速学习机理论	33
3.2.1 极速学习机	33
3.2.2 半监督极速学习机	35

3.2.3 增量式极速学习机.....	36
3.3 终端自适应的在线定位方法	38
3.3.1 方法原理.....	38
3.3.2 半监督增量式极速学习机.....	39
3.4 实验验证及分析	43
3.4.1 基于 SinC 函数模拟数据集的算法对比实验.....	43
3.4.2 基于定位数据集的算法对比实验.....	46
3.5 本章小结	52
第 4 章 终端自适应的蓝牙室内定位系统.....	53
4.1 系统架构与运行流程	53
4.2 系统具体设计	55
4.2.1 指纹采集客户端.....	56
4.2.2 位置服务云平台.....	57
4.2.3 在线定位 SDK.....	59
4.3 系统展示	60
4.3.1 功能演示.....	60
4.3.2 案例展示.....	63
4.4 本章小结	65
第 5 章 总结与展望	67
5.1 全文内容总结	67
5.2 未来工作展望	68
参考文献	71
致 谢	77
作者简历及攻读学位期间发表的学术论文与研究成果	79

图目录

图 2.1 基于 TOA 的定位方法示意图	11
图 2.2 基于 TDOA 的定位方法示意图	12
图 2.3 基于 AOA 的定位方法示意图	13
图 2.4 位置指纹定位方法示意图	16
图 2.5 位置指纹定位算法分类	17
图 2.6 终端采集的信号分析	23
图 2.7 异构终端采集信号比较	25
图 3.1 离线学习和在线学习流程比较	32
图 3.2 单隐层前馈神经网络 SLFN	33
图 3.3 终端自适应的在线定位方法原理图	39
图 3.4 SOSELM 算法流程图	42
图 3.5 带噪声标定值与真实值的关系图	44
图 3.6 模型预测均方根误差与 λ 的关系	45
图 3.7 各算法模型在 SINC 数据集下的预测误差比较	46
图 3.8 SOSELM 模型与 ELM 模型的回归分布	46
图 3.9 定位数据集采集和算法测试场景示意图	47
图 3.10 模型预测均方根误差与 λ 的关系	48
图 3.11 误差距离 ED 定义	48
图 3.12 各算法在不同定位终端数据集下的定位精度比较	50
图 3.13 SOSELM 模型随时间推移的定位精度比较	51
图 3.14 不同测试数据集下，不同终端模型定位精度比较	52
图 4.1 蓝牙室内定位系统框架图	53
图 4.2 蓝牙室内定位系统流程	55
图 4.3 指纹采集客户端功能模块示意图	56
图 4.4 指纹采集流程示意图	57
图 4.5 位置服务云平台功能模块示意图	58

图 4.6 在线定位 SDK 结构图	59
图 4.7 在线定位 SDK 工作流程图	60
图 4.8 指纹采集工具界面展示	61
图 4.9 指纹采集路线示意图	61
图 4.10 蓝牙定位演示图	62
图 4.11 定位轨迹示意图.....	63
图 4.12 购物中心室内定位应用展示	64
图 4.13 停车场室内定位应用展示	65

表目录

表 1.1 典型室内定位技术特点对比	4
表 2.1 室内无线定位方法对比	21
表 3.1 SOSELM 算法的数据集在不同终端的分布情况.....	49

第1章 引言

1.1 研究背景与意义

随着信息科技的高速发展，人类社会已开始步入移动互联网时代。在如今大数据时代的来临和信息化社会的刚性需求下，为用户提供更加精准化和多样化的基于位置的服务^[1](Location Based Service, LBS)则有着十分重要的意义和广阔的前景。LBS 服务通过相关定位技术来获取移动终端位置信息，将获得的信息反馈到用户或者通信系统，从而提供相应的服务。因此，如何确定位置是定位服务的核心问题。

在开放的室外环境，定位技术已经比较成熟，主要分为卫星导航定位技术和基于蜂窝网的定位技术。其中，卫星导航定位系统代表产品有美国的全球定位系统^{[2][3]}(Global Positioning System, GPS)、俄罗斯的Glonass系统^[3]、欧盟的伽利略(Galileo)系统^[4]和中国的北斗导航定位系统^[5](BeiDou Navigation Satellite System, BDS)。这类系统根据接收到的多颗卫星信号到达时间差来确定终端的位置，目前定位精度在10-15米左右，能够满足用户室外定位需求。而蜂窝网^[6]定位系统利用基站定位技术，定位精度取决于网络基站的分布和信号的覆盖情况。

但是在室内环境，如商超、写字楼、火车站等各种场所，由于建筑物屏蔽及室内环境复杂性，现有的GPS等定位系统的定位精度大幅降低以至于不具有实用性。然而不论是个人用户还是企业用户，对室内位置服务的需求都是十分迫切的。对个人用户而言，据统计，人们的日常生活有超过80%的时间处于室内环境^[7]。在超市、地下停车场、车站、候机大厅等场景下，用户可以通过定位技术来获得当前的位置。如在商场时，用户需要获知自己和目标商品的位置，以便方便快捷地选购商品，同时商家也可借此进行位置营销，刺激用户进店消费，提升商品销量。对于企业用户而言，通过集成室内定位技术可实时监控员工位置，如采矿行业，利用定位技术来监控旷工的位置状态，一旦出现险情可以迅速指导旷工疏散到安全区域，同时方便救助工作的开展；对于消防行业，室内定位技术也能给消防工作带来极大便利，由于消防员对火灾现场相对陌生，且环境中能见度很低，消防员往往无法确定自己的正确位置。有了室内定位技术，这一切都不再成为问题，救援的成功率和消防员自身的安全保障都能得到极大提升。在很多领域，室

内定位技术都发挥着至关重要的作用。

目前,室内定位的技术种类已经非常丰富,如ZigBee定位技术^[8]、超声波定位技术^[9]、射频识别(Radio-frequency Identification, RFID)定位技术^[10]、红外线定位技术^[11]、超宽带UWB(Ultra Wide-Band, UWB)定位技术^[12]等,部分定位系统的定位精度在特定范围内已经可达厘米级。但是这些定位系统在客户端和服务端均需要重新部署额外的专用设备,硬件成本比较高、定位覆盖的范围较小,因此推广和应用都受到很大限制。

随着国内“智慧城市”建设的不断开展,大部分城市都遍布了大量的无线局域网(Wireless Local Area Networks, WLAN)接入点(Access Point, AP)。随着AP覆盖区域的不断扩大,基于WLAN的室内定位技术^[13]应运而生。另外,蓝牙技术^[14]也不断发展,基于蓝牙4.0技术的低功耗蓝牙(Bluetooth Low Energy, BLE)具有扫描速度快、连接迅速、功耗超低等特性。适逢苹果公司推出iBeacon技术,基于iBeacon技术的BLE定位方法也受到了国内外研究机构以及企业和学者们的广泛关注。此外,如今智能手机终端的大量普及,智能手机终端包含的WIFI、蓝牙等通讯模块也会上述定位技术提供了广泛应用的基础。

1.2 室内定位技术与研究现状

1.2.1 常见室内定位技术研究现状

根据上节介绍,人们对室内位置服务的需求十分迫切,因此国内外学者包括学术界和工业界均做了大量研究,经过数十年发展,人们利用不同设备和不同原理设计出了多种室内定位技术,其中典型的室内定位技术有红外定位技术、超声波定位技术、蓝牙定位技术、超宽带UWB定位技术、射频识别定位技术、WLAN定位技术等。上述定位技术的定位性能和特点各不相同,分别应用在不同的工作场所。下面将对这些定位技术进行对比分析:

(1) 红外定位技术,该定位技术需要有专门的红外线发射设备和接收设备,一般需要将接收设备提前在场所中部署,接收器通过接收由用户终端发射的调制红外线进行定位解算。公认最早的基于红外线的定位系统是英国剑桥AT&T公司在1992年推出的Active Badge系统^[15]。虽然红外定位技术具有毫米级的室内定位精度,但是由于光线不能穿过障碍物,使得红外射线仅能视距传播,而且红外线只适合短距离传播,易受荧光灯或者房间内的灯光干扰。因此该定位系统虽在直

线视距传播环境中精度很高,但是由于对环境要求苛刻,易受干扰,且需要专用的硬件设备支持,部署复杂,因此应用局限性很高。

(2) 超声波定位技术,主要采用反射式测距法,以超声波传播速度和时间为参数,通过多边定位等方法确定物体位置。1999年,在Active Badge的基础上,AT&T剑桥实验室又开发了基于超声波定位方案的Active Bat定位系统^[16]。该定位系统整体定位精度较高,可达亚米级,但超声波受多径效应和非视距传播影响较大,且超声波频率受多普勒效应和温度影响,系统定位精度不稳定,同时也需要大量基础硬件设施,设备昂贵,系统部署与维护难度大、代价高,不利于大规模推广。

(3) 蓝牙定位技术,是一种无线网络技术,主要通过测量蓝牙基站的无线信号强度并利用信号传播模型或者指纹算法进行定位,定位精度可达米级。蓝牙定位技术的优势在于设备体积小,易于集成在PDA、PC以及智能手机终端中。近几年开始推广的蓝牙4.0技术在信号覆盖范围、功耗控制和连接速度等方面表现优异,而且随着集成了蓝牙功能的智能手机终端的大量普及,蓝牙定位技术的优势开始显现。但现有环境中低功耗蓝牙基站数量普遍较少,需要一定的部署工作量。

(4) 超宽带UWB定位技术,是近年来新兴的一种通信无线技术,它不需要使用传统通信体制中的载波,而是通过发送和接收具有纳秒或微秒以下的极窄脉冲来传输数据,通过计算发射端与接收端之间传输的脉冲信号的到达时间差来确定位置。可以从源信号中滤除反射信号,抗干扰能力很强,具有厘米级的定位精度。Ubisense^[17]是典型的UWB定位系统,其依赖专门的设备,包括UWB接收器、UWB参考标签和主动UWB标签,定位成本相对较高。

(5) 射频识别定位技术,该定位系统一般由射频标签和射频接收器组成,分为有源和无源两种射频识别技术。该技术通过测量到达接收端的信号时间差并利用几何原理来计算位置。典型的定位系统有Spot On^[18]和LANDMARC^[10]定位系统,其定位精度能达到2-3m,优点是非视距、占用空间小,但是作用距离近,不具有通信能力,抗干扰能力差,不便于整合到其他系统中,且用户的安全隐私保障和国际标准化都不够完善。

(6) WLAN定位技术,该定位技术的原理是利用环境中不同空间位置处具有不同的无线电信号特征,根据用户终端采集到的实时信号特征通过映射搜索匹配出对应的空间位置。用户处在无线网络覆盖的区域,无需额外的硬件设备支持,

靠定位软件就能估算出用户位置，定位成本较低。而且无线网络信号能在非视距路径下传播，因此具有较强的环境适应性。具有代表性的WLAN定位技术是微软公司的PADAR_[19]技术，该系统利用信号传播模型或指纹算法进行定位解算，定位精度能达到米级。

下表1.1列出了上述几种室内定位技术的特点。

表 1.1 典型室内定位技术特点对比

Table 1.1 Comparison of typical indoor localization technologies

室内定位技术	定位原理	定位精度	优点	缺点
红外线定位技术	通过光学传感器进行定位	最高可达毫米级	定位精度高、系统部署简单	直线视距传播、造价高、易受干扰
超声波定位技术	反射测距法，根据回波与发射波的时间差进行定位	可达亚米级	定位精度较高、系统结构简单	专门硬件、成本高、受非视距和多径效应影响大
蓝牙定位技术	基础网络连接模式，通过测量无线信号强度进行定位	可达米级	功耗低、易于集成、非视距传播	系统部署工作量较大
UWB定位技术	通过信号到达时间差进行定位	可达亚米级	抗干扰能力强、系统结构简单	专门硬件、成本高
RFID定位技术	射频方式，通过信号到达时间差进行定位	平均 2~3 米	非视距、体积小、成本低	抗干扰能力差、距离短、不易整合到其他系统
WLAN定位技术	利用接收的信号强度进行定位	可达米级	环境中 AP 丰富，无需额外部署、定位成本低	信号波动性大导致定位不稳定

除了上述经典的室内定位技术以外，研究人员还相继开发了一些具有实际应用价值的室内定位系统，如 ZigBee 定位技术、地磁定位技术、惯性导航定位技术_[20]、计算机视觉定位技术_[21]等，这些定位技术所使用的硬件设备和定位原理各有区别，根据其不同的定位精度和定位特性适用于不同的场所。通过表 1.1 分析对比可得，WLAN 定位技术和蓝牙定位技术都是基于接收的无线信号强度(Received Signal Strength,RSS)进行定位的无线定位技术，具有定位原理简单、适

应性好、定位精度较高等优点，目前已成为室内定位技术的研究热点。

1.2.2 终端差异性的室内定位技术研究现状

目前，室内无线定位方法可分为三角测量法^[22]、传播模型法^[23]和位置指纹定位方法^[24]。这其中，位置指纹定位算法具有较高的室内定位精度，无需额外增加专用硬件、定位成本低，而且也不需要知道场景中的信号基站部署情况，具有很强的灵活性和扩展性。因此，该算法受到了学术界和工业界的密切关注和深入研究。位置指纹算法是一种非测距算法，定位过程主要分为离线训练阶段和在线预测阶段两个步骤，离线训练阶段首先需要利用终端设备在所选定位区域建立 RSSI 指纹位置数据库，然后在在线预测阶段，根据用户定位终端设备采集到的实时 RSSI 信号特征与指纹库中指纹进行搜索匹配，得出估计位置。在上述过程中，存在这样一个问题，离线阶段建立好的 RSSI 指纹位置数据库是固定的，在后续定位阶段不会改变，而在线预测阶段用户使用的定位终端与离线阶段指纹采集的终端并不相同，这就是定位中出现的终端差异性问题。具体而言，由于移动终端的类型不同，不同品牌型号终端的硬件方案可能不一致，即使相同品牌相同型号的终端也存在如软件版本不同、硬件损耗不同等个体差异性，这些差异性将会影响到定位算法的定位精度。因此，我们需要设计相关的算法来尽量避免终端差异性问题带来的定位影响。

近年来，人们针对无线定位中的设备差异性问题的设备差异性已展开了很多相关工作。文献^[25]通过大量实验研究发现不同终端设备获取的 RSSI 之间存在线性变化关系。文献^[26]针对这种线性关系提出基于标定的方法来求解线性变化的斜率和截距参数，从而大大提高定位精度。相比于文献^[26]，文献^[28]和文献^[27]提出了免标定的定位方法，避免了数据标定的工作量，同时有效提升定位精度。不同于直接对数据进行调整，文献^[29]在传统的位置指纹定位方法中增加一个在线调整阶段，从而得到并不断修正线性变化的参数，使得定位精度不断提高。不局限于通过线性变化来解决设备差异性问题的非线性方法也被研究于解决该问题。文献^[30]通过核方法来减小概率估计的差异，利用合适的核宽来实现 3~4m 的定位精度。文献^[31]使用流形对齐的学习方法来解决设备差异性问题的设备差异性。

虽然已有一些解决针对设备差异性问题的室内定位算法工作，但已有方法还是存在很多不足。基于标定的方法需要大量的人工采集成本，实用性低；免标定

的处理方法不能同时解决线性变化的斜率和截距两个参数的影响，定位精度依然受到影响；非线性方法存在训练复杂，效率不高等问题。针对以上问题，本文将提出一种解决设备差异性问题的终端自适应定位算法，该方法可基于无标定数据进行训练，避免了标定难问题，且该方法能够在线学习，具有时效性优势。

1.3 本文的研究重点及贡献

本文主要对基于 RSS 的无线定位技术进行研究，并重点研究位置指纹定位算法。位置指纹算法无需额外增加硬件、定位成本低、定位范围广，无需知道 AP 的确切位置和发射功率即可实现定位。

尽管基于位置指纹的室内定位技术具有优势和应用前景，但是现有技术还存在一些实际应用面临的问题。如，室内环境高度复杂，信号的反射、衍射和多径效应都给基于 RSS 的定位技术带来了很大困难。另外，指纹定位技术在离线模型训练阶段大多需要相当丰富的训练样本才能学习出较好的定位模型，而更多的训练样本则意味着更长的模型学习时间和更大的数据采集工作量。此外，各类终端设备所采用的硬件方案不同，也导致了不同终端的定位性能差异。

针对上述问题，本文以基于位置指纹的 RSS 室内定位技术的关键技术为切入点，归纳总结现有的算法研究成果，针对基于位置指纹的 RSS 室内定位机制原理和终端自适应关键问题进行研究，并设计和实现一套定位系统，验证本文工作的有效性。论文主要工作可分为以下三部分：

1) 对现有的基于 RSS 的室内定位技术进行了较全面地归纳和总结，并讨论各种技术的优势与不足。在此基础上，对基于 RSS 的位置指纹的室内定位技术进行重点研究，包括定位的基本原理、技术发展的相关工作，介绍了几种典型的位置指纹定位匹配算法。

2) 针对传统指纹定位算法存在的问题，包括训练样本集标定难、模型时效性差以及终端设备差异性大等问题，提出一种针对设备差异性问题的增量式室内定位算法，对终端上已训练好的定位模型利用实时采集的无标定数据进行在线更新，以解决上述问题。

3) 设计并实现一个基于低功耗蓝牙的室内定位系统。包括蓝牙指纹数据采集客户端、位置服务云平台、在线定位 SDK 等，可供第三方企业、个人用户快速集成开发室内 LBS 应用，推动室内定位的应用发展。

1.4 本文的组织结构

全文组织结构共分为五章，下面简要介绍各章节内容：

第1章：绪论，主要介绍了室内定位技术的研究背景和意义，简要对比介绍了经典室内定位技术的优缺点，引出本文的研究内容并简单介绍了本文对室内定位技术的贡献，最后列出本文的组织结构。

第2章：讨论室内无线定位技术。首先介绍室内无线信号传播环境和无线信道特点，然后对现有无线定位方法进行深入探讨，尤其是详细研究基于RSS的位置指纹定位技术。

第3章：介绍本文在终端自适应在线定位算法上的研究工作。通过介绍机器学习的一些必要性的概念和学习方式，并引入极速学习机理论，为后续算法的介绍提供理论性的铺垫。然后提出基于半监督增量式极速学习机算法的终端自适应在线定位方法。并在实验验证部分，分别利用模拟数据集和实际定位数据集进行验证，比较不同算法模型和本文模型的定位精度，并且验证本文模型的终端自适应性能。

第4章：介绍基于低功耗蓝牙的室内定位系统。分别从系统的整体架构、运行流程、模块设计和划分以及系统展示等多个角度进行介绍。系统主要由蓝牙指纹数据采集客户端、位置服务云平台和在线定位SDK三个部分组成。本章将通过测试场景演示和典型实际应用案例说明本定位系统的有效性和实用性。

第5章：对整篇文章的工作进行了总结，并对下一步工作进行了展望。

第2章 室内无线定位技术

室内无线定位技术利用接收到的在空间中传输的不同强度的电磁波信号数据,采用定位算法解算出定位节点所处的坐标位置。室内定位不同于室外定位,一方面,室内空间范围相比室外要小、环境更加复杂,对定位精度要求更高;另一方面,室内环境中存在固定物件的遮挡、无线信号存在反射折射等情况,因此以GPS或北斗为代表的卫星导航定位系统在室内环境下已经不具有实用性。根据第1章介绍,基于RSS的室内定位技术定位精度较高、部署成本相对较低且系统具有较高鲁棒性,受到研究人员的欢迎。

本章第一节介绍室内无线信号传播特点;第二节分别介绍几种室内无线定位技术;第三节详细介绍位置指纹定位技术;第四节做本章小结。

2.1 室内无线信号传播特点

室内无线信号在室内空间传播的强度值反映了其信号能量值,信号能量的衰减受空间传输距离的约束,同时室内环境的复杂性对信号传播也产生明显的干扰,综合分析文献[1]-[34]阐述的各个因素,可以简要归纳出室内环境下无线信号传播具有以下特性:

(1) 信号传播衰减

电磁波在室内环境中传播过程中,由于不是真空环境,电磁波信号会被传播过程中的介质吸收,从而造成信号强度值的衰减。由于室内环境复杂,电磁波的传输介质也多种多样,大多时候无线信号在空气中传播,有时还要穿透墙壁,墙壁的材质也各不相同,因此信号的传播衰减是室内无线定位技术需要考虑的重要信号特性。

(2) 多径效应

多径效应是电磁波传播信道中的多径传输现象所引起的干涉延时效应[35]。在实际的无线电波传播信道中,会有许多时延不同的传输路径,各条传播路径会随时间变化,参与干涉的各分量场之间的相互关系也就随时间而变化,由此引起合成波场的随机变化,形成总的接收场的衰落。室内环境下,电磁波信号从信号基站发射后,会通过多条传播路径到达用户终端,多路信号的相互干涉会导致信号

的动态性变化,这种动态性变化受环境影响,难以预测,是无线定位技术面临的一个挑战性问题。

(3) 非视距传播

非视距传播(Non-Linear Of Sight, NLOS)^[36]是指信号基站与用户终端之间的直射路径被障碍物挡住后,无线信号只能在经过多次反射和衍射后到达接收端。此时测量的数据,如到达时间、时间差、入射角度等,将不能正确反映发送端与接收端的真实距离,这种现象是基于信号到达时间类算法和基于信号入射角度类算法的重要误差来源。

(4) 其他动态因素

室内环境的固件变、人流、温湿度、时间等因素的变化都会使同一位置接收到的无线信号发生明显的变化,因此多种干扰因素造成都会无线信号高动态性变化,室内无线定位技术需要设计相应的算法来降低这种信号高动态性带来的误差。

2.2 室内无线定位技术介绍

目前,室内定位算法思想主要借鉴于室外定位算法,典型算法包括 TOA(Time of Arrival)定位技术^[37]、TDOA(Time Different of Arrival)定位技术^[38]、AOA(Angle of Arrival)定位技术^[39]、RSSI 定位技术^[40]。下面将分别予以介绍。

2.2.1 基于 TOA 的室内定位技术

基于无线信号到达时间定位算法的基本原理是三角定位原理^[22]。定位过程中,用户定位终端会向其附近的基站发射无线信号,信号抵达各个基站的时间与用户终端和各个基站的实际距离呈正相关,理论上距离和时间正比关系,因此根据三角定位原理即可计算用户终端的位置坐标。基于 TOA 的定位方法示意图如图 2.1 所示。




图 2.1 基于 TOA 的定位方法示意图

Figure 2.1 Diagram of positioning method based on TOA

假定测量无线信号从用户定位终端到达基站的传输时长为 t ，则定位终端位置在以基站为圆心，半径 $r = c \times t$ (c 为光速)的圆上。当有三个或以上基站接收到来自定位终端的无线信号时，即可得到三个或以上的圆的公共交点，该点坐标即定位终端的位置坐标。不妨设定位终端的坐标为 (x, y) ，任取三个接收到定位终端无线信号的基站，已知其基站坐标分别为 (x_A, y_A) 、 (x_B, y_B) 、 (x_C, y_C) ，联立距离方程组 2.1。

$$\begin{cases} \sqrt{(x - x_A)^2 + (y - y_A)^2} = r_A \\ \sqrt{(x - x_B)^2 + (y - y_B)^2} = r_B \\ \sqrt{(x - x_C)^2 + (y - y_C)^2} = r_C \end{cases} \quad \dots(2.1)$$

求解方程组 2.1，即可推算出定位终端的估计位置。

基于 TOA 的定位方法要求时钟同步非常精准，由于电磁信号在大气环境下是接近光速传播，因此 $1 \mu s$ 的时间误差将会导致约 300 米的距离误差。而且上述推导是基于理论情况，实际室内环境中，多径效应和非视距效应等因素都会影响到信号测量值的准确性，最终影响定位精度。由于 TOA 方法对基站和定位终端的时钟同步要求过于苛刻，而这个条件又很难实现或者需要花费很高的成本，因此该方法的实用性不高。

2.2.2 基于 TDOA 的室内定位技术

与 2.1.1 小节所述方法相近，TDOA 方法同样需要测量时间参数，不同的是，

TDOA 方法是测量定位终端到多个基站传输时间差来进行定位。基于 TDOA 的定位方法示意图如图 2.2 所示。




图 2.2 基于 TDOA 的定位方法示意图

Figure 2.2 Diagram of positioning method based on TDOA

假定取接收到定位终端信号的三个基站 A, B, C, 设定位终端到 A, B, C 三个基站的距离分别为 r_A 、 r_B 、 r_C , 则定位终端到基站 A, B 的距离差为 $r_{AB} = r_A - r_B$, 因此, 定位终端位于以 A, B 为焦点, 与两个焦点距离差恒为 r_{AB} 的双曲线上; 同理, 定位终端也位于以 B, C 为焦点, 与两个焦点距离差恒为 r_{BC} 的双曲线上。两个双曲线的交点就是定位终端的实际位置。测量定位终端的信号到 A, B, C 三个基站的传输时长分别为 t_A 、 t_B 、 t_C , 则 $r_{AB} = |t_A - t_B| \times c$, $r_{BC} = |t_B - t_C| \times c$, 联立距离方程组 2.2。

$$\begin{cases} \left| \sqrt{(x-x_A)^2 + (y-y_A)^2} - \sqrt{(x-x_B)^2 + (y-y_B)^2} \right| = r_{AB} \\ \left| \sqrt{(x-x_B)^2 + (y-y_B)^2} - \sqrt{(x-x_C)^2 + (y-y_C)^2} \right| = r_{BC} \end{cases} \quad \dots(2.2)$$

求解方程组 2.2, 可算出多组坐标位置, 可通过先验知识, 确定具体的定位终端位置。

因为 TDOA 方法是根据定位终端发送的无线信号到各基站的传输时间差进行定位, 因此, 该方法不要求定位终端和各基站保持绝对、严格的时钟同步, 只需要各基站之间实现时钟同步即可。这个条件相比 TOA 方法要容易实现很多,

因此，TDOA 方法比 TOA 方法的实用性更好，应用更加广泛。

2.2.3 基于 AOA 的室内定位技术

与 TOA、TDOA 方法原理不同，AOA 方法是利用定位终端与接收基站不同角度来实现定位的。在二维空间中，可以通过测量定位终端和两个基站的之间的角度来确定终端位置。基于 AOA 的定位方法示意图如 2.3 所示。




图 2.3 基于 AOA 的定位方法示意图

Figure 2.3 Diagram of positioning method based on AOA

假定从接收基站 A，B 测得从定位终端发射的无线信号到达角分别为 θ_A 、 θ_B ，联立非线性方程组 2.3。

$$\begin{cases} \tan \theta_A = \frac{x_A - x}{y_A - y} \\ \tan \theta_B = \frac{x_B - x}{y_B - y} \end{cases} \quad \dots(2.3)$$

求解上述方程组即可得定位终端坐标。

基于 AOA 的定位方法原理比较简单，测量信号入射角度需要在接收基站旁边放置专用的天线阵列，但是由于受室内环境非视距传播效应的干扰，尤其是在多径密集的室内环境中，准确估计入射角度的难度较高，使得该方法定位成本较高，实用性较低。

2.2.4 基于 RSSI 的室内定位技术

基于 RSSI 的定位方法是利用无线信号接收基站采集的无线信号强度值 RSSI

进行位置估算。该方法最大的优势在于可以直接利用环境中已布设好的基础设施，如无线 AP 等，结合相关定位算法即可进行位置估算，无需额外硬件配置，方法简单、成本低，具有较强的实用性。利用 RSSI 值定位的方法主要分为两类：基于测距的方法^[41]和基于非测距的方法^[42]。

基于 RSSI 的测距方法需要利用信号传播损耗模型。研究分析表明，信号接收端接收的信号强度与收发设备的直线距离呈正相关，因此可以利用信号传播损耗模型将信号接收端接收的 RSSI 值转换成距离值。该方法的定位过程中，信号接收基站首先采集来自定位终端发送的无线信号 RSSI，然后利用信号传播损耗模型估算出基站和定位终端的实际距离，再根据三角定位原理，即可实现定位。上述定位思想与 TOA 方法的定位思想相近，不同点在于，TOA 方法测量信号传输的时长，根据实际环境中电磁波信号的近光速传播计算出基站和终端的距离；而利用 RSSI 的测距方法是使用信号传播损耗模型将 RSSI 值转换成距离值，从而计算出基站和终端的距离。

为了能够精确得出基站和终端的距离，信号传播损耗模型的准确性就有着至关重要的影响。近些年来，新的信号传播损耗模型不断被提出，较为经典的模型有自由空间损耗模型、对数路径损耗模型^[43]、Keenan-Motley 模型^[44]和衰减因子模型^[45]等，以对数路径损耗模型为例，估算定位终端与信号接收基站的距离公式如公式 2.4 所示。

$$\overline{PL}(d) = \overline{PL}(d_0) + 10n \log_{10}\left(\frac{d}{d_0}\right) + X_\sigma \quad \dots(2.4)$$

其中， $\overline{PL}(d)$ 表示收发设备间距离为 d 时的路径损耗，单位是 dB ； $\overline{PL}(d_0)$ 是收发设备距离为 d_0 时的路径损耗值，该值事先测量得出； n 是指路径损耗指数，它通常依赖于周围物质材料结构，一般取 2~4； X_σ 标识标准偏差为 σ 的正太随机变量，考虑环境因素， σ 一般取值范围为 3.0~14.1 dB 。

基于信号传播损耗模型的测距方法虽然相比上述 TOA、TDOA、AOA 方法具有一定优势，仅在软件层面即可实现定位，但是由于该方法对信号传播损耗模型的依赖性很强，加上室内环境中信号的多径效应、非视距效应等因素的干扰，使得该方法的精度不高，稳定性也较差，应用存在瓶颈。

非测距方法是另一种基于 RSSI 的定位方法，该方法的典型代表是位置指纹

(Finger Print, FP)定位方法[24]。该定位方法与上述测距方法不同,测距方法通过各种手段来获取定位终端与基站间的距离,同时还需要有基站位置等先验知识,而位置指纹方法无需计算定位终端和基站的距离,也不需要了解基站的位置,因此具有很强的灵活性。关于指纹定位方法的详细分析将在 2.4 节展开。

2.3 位置指纹定位方法

随着计算机硬件性能的快速发展,机器学习逐渐进入人们的视野,作为人工智能研究的核心内容,它的应用已遍及到人们生活的各个方面,如自然语言理解、计算机视觉、智能机器人等等。基于机器学习,人们将统计学习分支应用到室内定位方法中,研究出了基于位置指纹算法的室内定位方法。

位置指纹定位算法在 1999 年由微软公司首次在其推出的 PADAR 系统中使用。由于该算法只需利用现有基础网络设施即可定位,无需额外硬件支持,且不需先验获取信号基站的位置,同时定位精度相对较高,因此该算法受到了学术界和工业界的密切关注和深入研究,这也是本文的主要研究内容。本节将介绍位置指纹定位方法的基本原理和典型的指纹定位匹配算法,为后续章节介绍本文对已有算法的创新和改进工作做铺垫。

2.3.1 位置指纹定位方法原理

指纹定位方法是一种场景分析方法[46],将环境中某场景特征与位置坐标建立映射关系,依据场景特征进行位置估算。对基于无线信号的室内位置指纹算法而言,这种场景特征可以选取为无线信号电特征 RSS,室内不同空间位置的 RSS 特征具有唯一性,因此可以利用这种特征向量与位置的映射关系,估算出定位终端的位置。具体定位过程中,首先在定位区域内的参考点采集 RSS,得到参考点位置指纹,然后利用机器学习算法训练出指纹与空间位置的映射关系,建立位置指纹数据库;然后在定位阶段,将定位终端实时采集到的 RSS 特征与位置指纹数据库中的指纹进行对比匹配即可得到终端位置,从而实现定位。因此,位置指纹定位方法根据实施步骤可分为离线训练阶段和在线预测阶段,如图 2.4 所示。

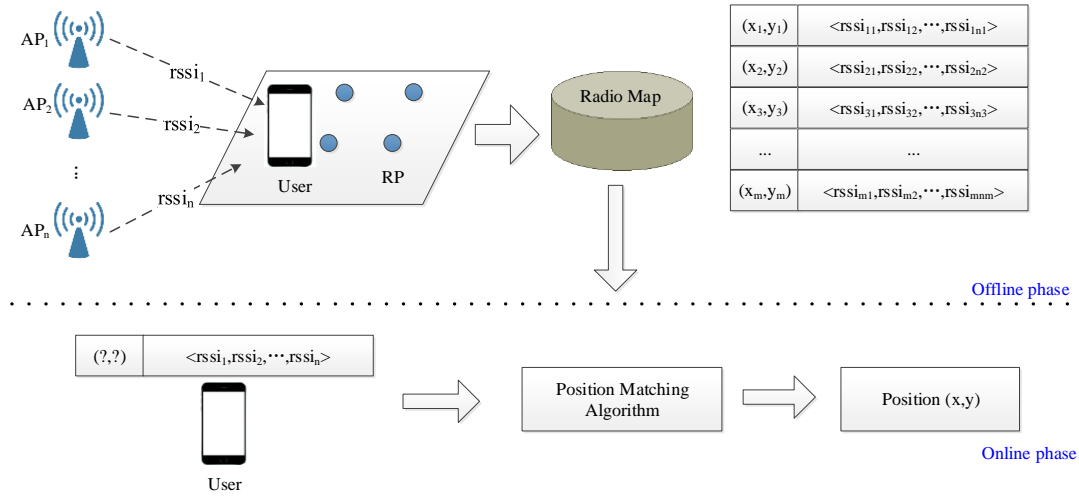


图 2.4 位置指纹定位方法示意图

Figure 2.4 Diagram of positioning method based on Fingerprint

离线训练阶段：在待定位区域按照一定规则合理选取若干点作为位置指纹参考点(Reference Point, RP)，采集参考点位置的 RSS 特征，一般而言，每个参考点都会采集到多个信号基站的 RSSI，表示为 $\langle rssi_1, rssi_2, \dots, rssi_n \rangle$ 向量，其中 n 为当前参考点采集到的信号基站个数。同时，获取当前参考点的物理位置坐标 $Y(x, y)$ ，与 RSSI 向量共同组成当前参考点的一条指纹，如式 2.5 所示。将所有参考点的指纹信息存储在数据库中，形成一个二维矩阵，一般称之为信号图(Radio Map)。

$$(\langle x, y \rangle, \langle rssi_1, rssi_2, \dots, rssi_n \rangle) \quad \dots(2.5)$$

在线预测阶段：该阶段的目标是估算出定位终端的位置。当定位终端处于定位区域中，终端采集当前位置的 RSS 特征序列 $\langle rssi_1, rssi_2, \dots, rssi_{n^*} \rangle$ ，其中 n^* 为定位终端当前采集到的信号基站个数。在指纹信息信号图的基础上，通过特定的搜索匹配算法，最终估算出定位终端的位置坐标，完成定位过程。

上述定位过程中，在线搜索匹配算法实现了将在线预测阶段采集的 RSS 特征序列输出为位置坐标的任务，这一步是指纹定位方法的核心一步，在线搜索匹配算法的好坏直接决定了定位系统的定位性能。下一小节将介绍一些典型且常用的指纹定位匹配算法。

2.3.2 典型室内指纹定位匹配算法

上一小节主要介绍了位置指纹定位的基本原理，该定位方法的重点在于离线

训练阶段位置指纹数据库的建立和在线预测阶段合理选择使用搜索匹配算法进行位置估算。

近些年来，随着指纹定位算法的不断发展，各种搜索匹配算法也不断涌现，根据训练指纹特征的不同可以将匹配算法分为两类：确定性算法和概率性算法。确定性算法中较为典型的方法是最近邻算法(Nearest Neighborhood, NN)、K 近邻算法(K-Nearest Neighborhood, KNN)、加权 K 近邻算法(Weighted K-Nearest Neighbor, WKNN)等；概率性算法主要就是朴素贝叶斯算法。具体分类如下图 2.5 所示。本小节将逐一介绍以上这些算法。

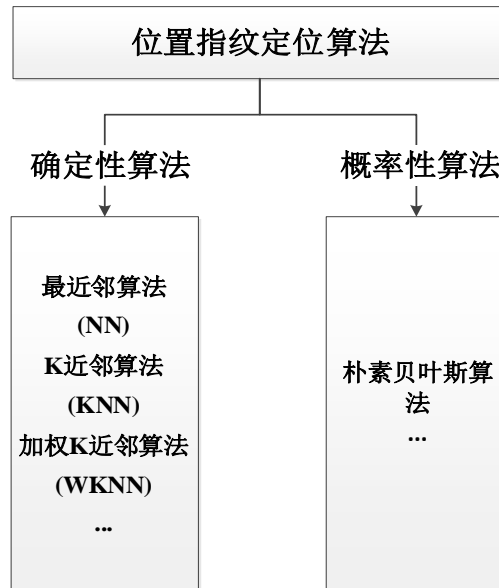


图 2.5 位置指纹定位算法分类

Figure 2.5 Classification of positioning method based on Fingerprint

1、最近邻算法(NN)

最近邻算法^[47]是一种最简单的基于指纹的定位算法。它的定位过程如下：

a)离线训练阶段，用户使用 RSS 采集工具在各个参考点采集环境的 RSS 特征，包括 RSSI 序列、基站的标识 ID 信息以及当前参考点的位置坐标信息，然后按照如式 2.6 的指纹格式构建位置指纹数据库。

$$FP_i = \langle x_i, y_i \mid ID_{i1}, rssi_{i1}, ID_{i2}, rssi_{i2}, \dots, ID_{in}, rssi_{in} \rangle \quad \dots(2.6)$$

其中， FP_i 表示指纹数据库中的第 i 个指纹， (x_i, y_i) 表示当前指纹点的位置坐标， $\langle ID_{ij}, rssi_{ij} \rangle (0 \leq j \leq n)$ 表示第 i 个指纹中接收的第 j 个基站的 ID 信息和信号强度值。

b)在线定位阶段,定位终端利用相关定位软件工具采集周围环境中的 RSS 特征信息,形成终端定位指纹,指纹格式如下式 2.7 所示。然后定位工具将根据最近邻算法将该指纹信息与位置指纹数据库中的所有指纹信息进行比对,选取出相似度最高的训练指纹的位置坐标作为终端的位置估计坐标。

$$FP_t = \langle ID_{t1}, rssi_{t1}, ID_{t2}, rssi_{t2}, \dots, ID_{tm}, rssi_{tm} \rangle \quad \dots(2.7)$$

具体而言,最近邻算法计算终端定位指纹 FP_t 与位置指纹数据库中每一条指纹 FP_i 的距离,指纹特征间距离最小即视为相似度最高,则该条训练指纹的位置即为终端的定位结果。如式 2.8 所示。

$$\overline{FP} = \min(dis(FP_t, FP_i)) \quad \dots(2.8)$$

而指纹的距离计算公式如 2.9 所示。一般取值 $q = 2$, 这时 $dis(FP_t, FP_i)$ 也称为欧氏距离(Euclidean Distance)。

$$dis(FP_t, FP_i) = \left(\sum_{m=1}^M |rssi_{tm} - rssi_{im}|^q \right)^{\frac{1}{q}} \quad \dots(2.9)$$

其中, M 为指纹数据库中指纹总个数, $rssi_{tm}$ 表示终端定位指纹 FP_t 中第 m 个基站的信号强度值, $rssi_{im}$ 为数据库中 FP_i 指纹的第 m 个基站的信号强度值。

2、k 近邻算法(KNN)

k 近邻算法^[48]是基于最近邻算法的一种改进算法。最近邻算法选取与终端定位指纹相似度最高的 1 条训练指纹的位置坐标作为定位结果, k 近邻算法与之不同的是, k 近邻算法选取相似度最高的前 k 个训练指纹点位候选点, 通过求均值的方式计算出定位终端的位置坐标。位置计算公式如 2.10 式。

$$(x, y) = \frac{1}{k} \sum_{\alpha=1}^k (x_{\alpha}, y_{\alpha}) \quad \dots(2.10)$$

其中, (x_{α}, y_{α}) 表示前 k 个训练指纹的第 α 个指纹对应的位置坐标。当取值 $k=1$ 时, k 近邻算法即退化为最近邻算法。

3、加权 k 近邻算法(WKNN)

加权 k 近邻算法^[10]在 k 近邻算法的基础上再做一步优化。k 近邻算法通过计算前 k 个候选点位置坐标的平均值来得到, 而事实上, 前 k 个候选点与终端定位指纹的相似度并不相同, 因此不同候选点对最终位置计算的贡献度是不一样的。加权 k 近邻算法考虑到这一点, 将每个候选点的位置坐标乘以一个相似度相关的

权重，来估算出最终终端的位置坐标。位置计算公式如 2.11 式。通常情况下，权重的大小取决于定位指纹与候选点指纹的特征距离，但是在有些场景下，影响权重大小的因子可能不限于距离，也可能是方差、基站的硬件差异性等等。

$$(x, y) = \frac{\sum_{\alpha=1}^k \frac{1}{dis_{i\alpha} + \omega} \times (x_{\alpha}, y_{\alpha})}{\sum_{\beta=1}^k \frac{1}{dis_{i\beta} + \omega}} \quad \dots(2.11)$$

其中， $dis_{i\alpha}$ 表示定位终端指纹 FP_i 与候选点指纹 FP_{α} 的特征距离， ω 是一个极小值，避免 $dis_{i\alpha} = 0$ 时分母为 0，出现计算错误。

上述三种近邻算法都是确定性指纹定位算法，下面介绍概率性指纹定位算法。

4、朴素贝叶斯算法

与确定性指纹定位算法不同，概率性指纹定位算法从概率的角度去解决定位问题。朴素贝叶斯算法^[49]是典型的概率性指纹定位算法。在离线训练阶段，假设一共采集了 M 条位置指纹，记为 $\{FP_1, FP_2, \dots, FP_M\}$ ，与指纹一一对应的参考点位置坐标为 $\{L_1, L_2, \dots, L_M\}$ ，其中， L_i 表示第 i 个参考点的位置坐标 (x_i, y_i) 。在在线预测阶段，假设定位终端采集的一条指纹共有 n^* 个基站的信号强度值，表示为 $FP^* = \langle ID_1, rssi_1, ID_2, rssi_2, \dots, ID_{n^*}, rssi_{n^*} \rangle$ 。根据概率算法思想，在已知待定位终端指纹 FP^* 的前提下，后验概率最高的位置坐标 L_i 即可作为最终的估算位置坐标，因为后验概率最高表示定位终端处于位置 L_i 时，采集到指纹 FP^* 的概率最大。为了知道指纹 FP^* 在每个参考点的后验概率 $P(L_i | FP^*)$ ，根据贝叶斯定理，推导出 $P(L_i | FP^*)$ 如下 2.12 式所示。

$$P(L_i | FP^*) = \frac{p(FP^* | L_i) \cdot p(L_i)}{p(FP^*)} = \frac{p(FP^* | L_i) \cdot p(L_i)}{\sum_{j=1}^M p(FP^* | L_j) \cdot p(L_j)} \quad \dots(2.12)$$

其中， $p(L_i)$ 表示待定位终端位于 L_i 处的概率，通常情况下，可以认为 $p(L_i)$ 是均匀分布的，则 $p(L_i) = \frac{1}{M}$ 。而 $\sum_{j=1}^M p(FP^* | L_j)$ 是对所有参考点位置采集到指纹 FP^* 的求和，因此在一次定位过程中，该值是一个常数值。这时，概率 $P(L_i | FP^*)$ 仅依赖于概率 $P(FP^* | L_i)$ 。我们假定在定位区域内，各信号基站之间相互独立，互

不影响。则根据概率学理论，可将 $P(FP^* | L_i)$ 表示为式 2.13 所示。

$$p(FP^* | L_i) = p(rssi_1 | L_i) p(rssi_2 | L_i) \cdots p(rssi_n | L_i) \quad \dots(2.13)$$

一般假设参考点处的 rssi 值分布满足高斯分布，其概率表示为：

$$p(rssi | L_i) = \frac{1}{\sqrt{2\pi}\delta} \exp\left[-\frac{(rssi - \mu)^2}{2\delta^2}\right] \quad \dots(2.14)$$

其中， μ 、 δ 分别表示这一参考点接收到第 i 个基站的 rssi 值的均值和标准差，我们需要事先对每个参考点进行信号预采集和处理，得到每个参考点的所有的基站信号高斯分布。

通过以上计算，我们已经可以得到后验概率最高的参考点位置坐标，实现最终的位置估算。然而类似于最近邻算法思想，采用单一参考点位置作为最终估算位置可能会使定位精度不足，我们可以通过加权的方式来抵消这种误差，权重选用每个参考点的后验概率，则位置计算公式如式 2.15 所示。

$$(x, y) = \sum_{i=1}^M (p(L_i | FP^*) \cdot (x_{L_i}, y_{L_i})) \quad \dots(2.15)$$

与确定性定位算法相比，概率性定位算法的优势在于适应性更强，定位效果更加稳定，环境干扰造成的信号波动对算法的影响相对较低。但概率性定位算法在离线训练阶段需要采集大量样本进行指纹训练，需要得到信号的概率统计分布，这些信息的获取大大增加了工作量和计算复杂度，因此该方法实用性也受到一定局限。

2.3.3 指纹定位方法的优缺点

在上面几小节的内容中，本文介绍了基于 RSSI 的位置指纹定位方法的基本原理、定位流程和常见的定位匹配算法。为了能够在室内场景中科学合理地选用位置指纹定位方法，本小节将分析位置指纹定位方法相比于其他定位方法的优势，以及位置指纹定位方法面临的问题和挑战。

2.3.3.1 位置指纹定位方法的优点

在实际复杂室内环境中，无线信号的空间传播会受到很多外界因素的干扰，尤其是多径效应、非视距效应等因素影响，测量信号传输时长、终端信号到基站的入射角度以及信号强度值 rssi 等物理量的数值都会存在较大的误差，导致定位误差较高。位置指纹定位方法将环境中无线电信号特征与位置建立映射关系，通

过特征信息匹配进行定位,从而避免了信号传输时长和信号入射角度等物理量的直接测量,对信号强度的绝对值测量要求也不高,因此该方法在定位难度上相对较低,可以满足大部分室内场景的需求。尤其突出一点的是,传统的基于测距的定位方法都需要掌握信号基站的位置信息,而位置指纹定位方法并不需要这一信息,因此,在一些 AP 位置分布未知或 AP 空间分布十分复杂的室内环境中,位置指纹方法的优势更加突出。

下表 2.1 对比展示了几种室内无线定位技术的特性。从表格中可以看出,相比于其他方法,位置指纹定位方法具有成本低、定位精度较高、适用场景广、实施难度较低等优势,定位过程可以仅依赖于移动终端上的定位软件客户端,因此受到了广大用户的欢迎,目前基于 RSS 的指纹定位方法已成为室内无线定位方法研究的主流。

表 2.1 室内无线定位方法对比

Table 2.1 Comparison of typical indoor wireless localization methods

特性 方法	TOA/TDOA法	AOA法	传播模型法	位置指纹法
定位精度	高	高	较低, 依赖于模型	较高
度量指标	时间	角度	RSSI	RSSI
额外硬件	需要	需要	不需要	不需要
成本	高	高	低	低
AP 位置信息	需要	需要	需要	不需要
样本数据	不需要	不需要	需要	需要

2.3.3.2 位置指纹定位方法面临的问题

虽然位置指纹定位方法有上述的优点,但是该方法在应用上仍然受到一些问


题和挑战的制约，下面将分别介绍。

（1）数据标定难问题


位置指纹定位方法中的数据标定是指：在离线训练阶段，需要采集多个参考点的训练指纹，每组指纹都需要添加当前参考点的位置信息。为了得到更精准的定位效果，通常需要在布局合理的前提下，尽量减小参考点的分布间距。待定位区域内参考点设置的密度大小和每个参考点位置训练样本数据采集的时长和频率，决定了数据标定的工作量。减小参考点的分布间距，可以使得参考点分布的更加密集，有利于提高空间信号特征对物理位置映射的精确度，保证定位的准确度。在大范围的室内定位区域，参考点的数量将非常之多，每个参考点还需要采集多个样本来降低误差；为了获取参考点的位置坐标，还需要建立室内定位区域的地图，在统一的地图上标记所有参考点的位置信息。这种离线训练过程将带来巨大的工作量，随着定位区域的增大，这种工作量还将指数增加。同时，对于已经建立好的位置指纹数据库，由于室内环境的复杂多变，信号基站可能出现数量增减、位置变化等情况，导致原数据库中信号特征与物理位置的映射关系遭破坏。因此为了保证位置指纹数据库的有效性，数据标定的工作还需要定期进行，这又无疑大大增加了指纹定位方法的工作量。

（2）模型时效性问题

基于 RSS 的位置指纹定位方法依据定位区域的 RSS 特征与物理位置的映射关系，使得该方法可以通过接收 RSS 信号特征来估算位置信息。该方法的前提在于训练阶段的映射关系和定位阶段的映射关系保持一致。然而，根据 2.1 节分析可得，室内无线信号传播环境复杂多变，同一物理位置接收的 RSS 信号具有高动态性和随机性^{[50][51]}，信号的这种特性使得上述的映射关系难以稳定一致，导致位置估算出现误差。下图 2.6(a)显示了某终端在同一位置采集同一蓝牙信号基站的信号变化情况；图 2.6(b)显示了 2.6(a)数据的信号统计分布。



(a) 同一 AP 在一段时间内的信号变化情况



(b) 同一 AP 在一段时间内的信号变化统计

图 2.6 终端采集的信号分析

Figure 2.6 Signal analysis of terminal acquisition

根据信号传输模型 2.4 式，结合文献[52]，在实际测量中，接收信号强度与信号传输距离的关系取下式 2.16：

$$RSSI = -(10n \lg d + A) \quad \dots(2.16)$$


其中 d 代表信号传输距离，一般取 $n=2$ ，则当信号强度波动幅度在 20dBm 时，简单计算可以得出 $\frac{d_1}{d_2} = 10$ ，也就是信号传输距离有 10 倍之差。在图 2.6 中，

同一 AP 的信号变化幅度最大达到约 20dBm，说明信号的波动性很大。

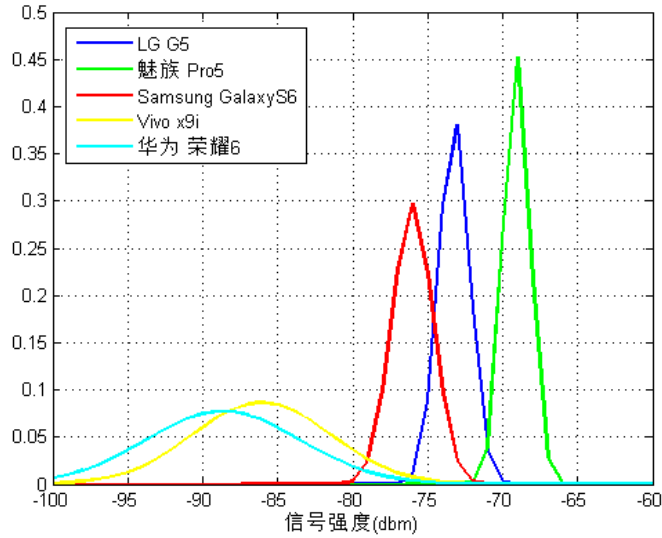
(3) 设备差异性问题

在位置指纹定位方法的离线训练阶段，我们需要通过某种终端设备去采集位置指纹，然后构建位置指纹数据库，之后在在线定位阶段，使用待定位的终端设

备去采集定位指纹，与数据库中指纹进行对比，从而完成定位。在此过程中，影响定位精度的关键在于离线训练数据和在线预测数据是否满足同一模型分布。然而训练设备和定位设备绝大多数情况是不相同的，定位用户各不相同，定位终端设备也种类繁多。在这种背景下，由于不同终端设备的无线硬件方案难以统一，而不同的无线电芯片对 RSSI 的定义各有差异，因此即便不同终端在同一时刻同一地点进行信号采集，RSSI 值也可能不一样。下图 2.7(a)显示了不同终端在同时同地点采集蓝牙基站的信号情况；图 2.7(b)显示了各品牌终端扫描信号的正态分布，不同均值表明不同终端无线电芯片对 RSSI 定义的差异性，而不同方差则反映了不同终端扫描的稳定性差异。



(a) 异构终端采集的信号对比



(b)异构终端采集的信号变化正态分布

图 2.7 异构终端采集信号比较

Figure 2.7 Signal contrast of different terminals

从上图可以看出，不同终端的无线信号扫描性能差异较大，最大信号差值达到了 20dBm，这种差异性已经接近上文模型时效性中信号的波动性，表明设备差异性问题对模型时效性问题对指纹定位方法精度的影响是同一量级的。不同设备扫描无线信号存在差异性，意味着不同设备对环境中的无线信号特征与物理位置映射关系的刻画不同，因此，某一终端设备训练出来的定位模型应用在其他终端进行位置估算时，也将出现定位误差。

2.4 本章小结

本章首先简要介绍了室内环境下无线信号传播的特性，然后对室内定位所涉及的几种主要算法进行了介绍，包括 TOA 算法、TDOA 算法、AOA 算法和基于 RSSI 的室内定位算法，详细介绍了基于 RSSI 的指纹定位方法，从基本原理、定位流程、常见匹配算法和算法优缺点等角度进行了论述。

针对目前指纹定位方法还存在的一些问题，本文将对已有的基于 RSSI 指纹的定位算法进行改进，提高指纹定位精度。在后续章节中，将详细介绍本文的改进算法并通过实验进行验证。

第3章 终端自适应的在线定位算法研究

上一章对基于机器学习理论的位置指纹定位方法做了系统性的介绍,同时与几种典型的室内无线定位方法进行了对比分析,为本章的内容提供了理论支撑。上一章还提出了目前传统位置指纹定位方法面临的问题和挑战,包括数据标定难问题、模型时效性问题和设备差异性问题。本章将以这三个问题为切入点,引入极速学习机算法,通过对算法进行创新和改进,来解决上述三个问题,并通过实验进行验证。

本章第一节介绍机器学习的基本概念和几种机器学习分类方法,为后面章节的展开进行铺垫;第二节首先引入一种单隐层神经网络学习算法——极速学习机,然后对介绍该算法的改进内容;第三节介绍本文提出的在线增量式极速学习机算法;第四节通过实验验证算法的有效性;第五节对本章内容进行总结。

3.1 机器学习方法概述

自从计算机被发明以来,人类就有着用计算机代替人脑劳动的梦想。为了实现这一梦想,人们也在不断探索和努力。随着信息社会的高速发展,在面对处理海量的知识和信息时,人脑具有的自然智能已逐渐力不从心,人类迫切需要用智能的机器来放大和延伸自己的智能。学习是人类智能的重要体现,而机器学习是使计算机具有智能的根本途径。

本节首先将简要介绍机器学习的概念,然后介绍机器学习领域中的几种分类方法,为后续章节内容的展开做铺垫。

3.1.1 机器学习概念

人类智慧的一个很重要的方面就是依据实例进行学习的能力,通过对已知事实的分析总结得出事物发展规律。这种规律不但可以去解释现有的实例,也能够对未来的现象进行预测,指导人们的行动。在人工智能发展过程中,人们希望计算机也能模拟出这种学习能力,这就是我们所说的基于数据的机器学习问题,也可简称为机器学习(Machine Learning)问题。

学习能力是智能的一个重要体现,但至今为止,人们对学习的机制还不完全

清楚。学术界目前对机器学习的定义尚未统一。Tom M.Mitchell 在其著作《Machine Learning》中指出，机器学习就是指“计算机利用经验自动改善系统自身性能的行为”；Alpaydin^[53]认为，“机器学习是用数据或以往的经验，以此优化计算机程序的性能标准”。简而言之，机器学习是指通过计算机学习数据中的内在规律性信息，获得新的经验和知识，以提高计算机的智能性，使计算机能够像人那样去决策。

从数学模型的角度来看，一般而言，机器学习从训练数据(training data)集合中学习模型，对测试数据(test data)进行预测。训练数据由输入（或特征向量）与输出对组成。对于给定的输入 X ，在一组函数集 $\{f | Y = f(X)\}$ 中选取最优模型函数 f 作为决策函数，由 $f(X)$ 给出相应的输出 Y ，它能够最好地估计出输入和输出的依赖关系。这个最优函数也就是我们得到的信息学习模型。

为了合理度量模型预测的好坏，机器学习引入损失函数(loss function)的概念，损失函数是 $f(X)$ 和 Y 的非负实值函数，记作 $L(Y, f(X))$ 。损失函数要根据实际问题来确定，下面介绍两个常见问题的损失函数：

(1) 模式识别问题的 0-1 损失函数(0-1 loss function)

$$L(Y, f(X)) = \begin{cases} 1, & Y \neq f(X) \\ 0, & Y = f(X) \end{cases} \quad \dots(3.1-1)$$

(2) 回归问题的平方损失函数(quadratic loss function)

$$L(Y, f(X)) = (Y - f(X))^2 \quad \dots(3.1-2)$$

损失函数的期望称之为风险函数(risk function)或期望损失(expected loss)，如式 3.3 所示。

$$R_{\text{exp}}(f) = E_p[L(Y, f(X))] = \int_{X \times Y} L(y, f(x))P(x, y)dxdy \quad \dots(3.1-3)$$

其中， $P(x, y)$ 是输入、输出变量(X, Y)的联合分布函数。学习的目标就是选择期望风险最小的模型。

3.1.2 机器学习算法的常见形式

根据训练数据是否存在人为标注，可以对机器学习方法分为多种类型：监督

学习、无监督学习、半监督学习和强化学习。本小节将分别介绍这几类机器学习方法。

(1) 监督学习(Supervised Learning)

监督学习的数据集包括初始的训练样本集和人为对样本的标注信息,数据格式通常为(特征,结果),记为 (x, y) ,其中 y 表示对实例 x 的某种标注。如果 y 的类型是离线型,那么这种监督学习对应模式分类问题;如果 y 的类型是连续实数,那么则对应着回归问题。学习的目标是根据标注的特征从训练数据集中学习到样本空间与目标空间之间的依赖关系,然后在测试数据集中依据这个依赖关系对结果进行预测,输出测试特征对应的结果。因此,监督学习的根本目标是训练模型对新样本的适应能力,也即是模型的泛化能力(*generalization ability*)。

较常见的监督学习算法包括逻辑回归(Logistic Regression)算法[54]、决策树(Decision Tree)算法[55]、Boosting 和 Bagging 算法[56]、人工神经网络(Artificial Neural Network)算法[57]和支持向量机(Support Vector Machine)算法[58]等。典型的监督学习应用有回归分析、任务分类等。

(2) 无监督学习(Unsupervised Learning)

在无监督学习[59]中,只能观察样本集数据的特征,没有结果的度量,它并不需要某种目标变量和训练数据集。无监督学习的目标是通过学习找到数据间的内在模式和统计规律,从而获取样本数据的结构特征,因此,无监督学习的根本目标是基于样本数据的结构特征对样本进行密度估计。数学表述上,若用 $X = (x_1, x_2, \dots, x_n)$ 表示 n 个独立同分布样本的集合,那么无监督学习就是希望在集合 X 中发掘出分布特征。

较常见的无监督学习算法包括自动编码器(Auto Encoder)算法[60]、受限玻尔兹曼机(Boltzmann Machine)算法[61]、深度置信网络(Deep Belief Networks)算法[62]等。典型的无监督学习应用有聚类分析、关联规则分析等。

(3) 半监督学习(Semi-supervised Learning)

监督学习中,标记的训练数据集的获取是相当困难的,与标记数据相对而言,无标记数据集的获取更加容易。半监督学习 **Error! Reference source not found.**[63]是近年来机器学习领域一个新兴的内容。半监督学习算法是一种同时利用标记和无标记数

据的算法，它的训练样本数据集中既包含了标记的数据集，又有大量的无标记的数据集。已有的研究证明，在假定标记样本和无标记样本服从相同的边缘分布的前提下[64]，无标记的样本能够帮助改进学习性能。在这个原理基础上，半监督学习对无标记的数据的标签进行预测，然后合并到标记的数据集中，使得训练的学习模型具有更好的预测效果。

具体而言，假设样本空间 $X = \{x_i, i = 1, 2, \dots, n\}$ 由两部分数据组成： l 个标记样本 $X_l = (x_1, x_2, \dots, x_l)$ ，对应的标记信息为 $Y_l = (y_1, y_2, \dots, y_l)$ ； u 个无标记样本 $X_u = (x_{l+1}, x_{l+2}, \dots, x_{l+u})$ ，对应的标记信息为空。一般而言，无标记样本数远大于标记样本数，即 $u \gg l$ 。半监督学习方法将综合利用标记样本 $X_l = (x_1, x_2, \dots, x_l)$ 和无标记样本 $X_u = (x_{l+1}, x_{l+2}, \dots, x_{l+u})$ 来学习样本空间 X 到目标空间 Y 的映射，并使半监督学习得到的模型性能比仅适用标记样本得到的模型性能更优。

在众多半监督学习方法中，图方法是半监督学习相当活跃的研究领域。这类方法基于流形学习[66]，对数据之间的关系采用图来刻画。图的节点表示数据样本，图的边被赋予权重，表示样本之间的相似度。一般，权重越大表明样本间相似度越高，如果两个样本点之间没有边相连，则表示两个样本点没有相似性。相似性计算是构建图的关键，相似的顶点应该尽可能标为相同或相近的类别标记，使图的分布尽量平滑。基于图的半监督学习的优势在于相似性计算的方式可以根据实际问题灵活设计，从而保证算法的性能。

流形正则化(Manifold Regularization)[67]是一种经典的基于图的半监督学习方法。它通过构建拉普拉斯图算子来使用无标记样本数据，很多算法通过引入流形正则化方法实现半监督学习能力。该方法基于流形假设的基础上。流形假设认为如果所有样本都处于一个很小的局域邻域内，那么他们就应该具有相近的类别标记。数学表现形式为：如果 x_1 和 x_2 在同一个局部邻域中，则 x_1 和 x_2 的条件概率 $P(y|x_1)$ 和 $P(y|x_2)$ 也是相近的，即：

$$L_m = \frac{1}{2} \sum_{i,j} \omega_{ij} \|P(y|x_i) - P(y|x_j)\|^2 \quad \dots(3.1-4)$$

其中， ω_{ij} 表示 x_1 和 x_2 的相似度。上式进一步简化为式(3.1-5):

$$\hat{L}_m = \frac{1}{2} \sum_{i,j} \omega_{ij} \left\| \hat{y}_i - \hat{y}_j \right\|^2 \quad \dots(3.1-5)$$

上式矩阵形式为 $\hat{L}_m = Tr(\hat{Y}^T L \hat{Y})$ ，其中 $Tr(.)$ 表示矩阵的迹， $L = D - W$ 表示图的拉普拉斯算子， D 是 $D_{ij} = \sum_{j=1}^{l+u} \omega_{i,j}$ 的对角矩阵，其中 l 表示有标记样本个数， u 表示无标记样本个数。

(4) 强化学习(Reinforcement Learning)

强化学习^[68]不同于监督学习方法那样通过已标注的信息来告知采取何种行为，而是通过试错(trial-and-error)来发现最优行为策略。强化学习过程中，如果一个动作导致环境的正向奖赏，即为强化信号，以后该动作产生的趋势便会加强；反之，该动作产生的趋势就会变弱。这与生理学中的条件反射原理一致。常见的强化学习算法包括 TD 学习算法^[69]、Q-学习算法^[70]、Sarsa 算法^[71]等。强化学习的应用主要有非线性控制、机器人控制、人工智能、组合优化、模式识别等领域。

基于 RSS 指纹特征进行位置估算本质上是一种回归问题。传统的位置指纹定位方法通过采集有标记的训练样本数据集，利用监督学习的方法进行位置预测。然而，实际大规模室内环境的标记训练样本的数据采集需要消耗巨大的工作量，代价过高，限制了基于监督学习的位置指纹定位方法的应用。另一方面，无标记的 RSS 指纹却很容易采集得到，但是仅根据无标记的 RSS 指纹并不能进行位置预测，基于完全无监督的机器学习方法主要是对样本内在结构进行分析，不适于回归问题。因此，本文将基于半监督学习方法，对传统位置指纹方法进行改进，利用大量容易获取的无标记数据对模型进行修正和优化。

3.1.3 离线学习与在线学习

随着云计算、物联网、社交网络等新兴信息技术和互联网应用模式的高速发展，各行各业产生的数据量爆发性增长，人类社会也逐渐进入大数据时代。根据数据的特点，可分为批量式数据和流式数据。批量式数据是一种静态型数据。传统的机器学习往往是批量模式的，假设所有训练数据都预先给定，然后进行训练和预测，将所有的训练样本一次性学习完之后，学习的过程就已结束，后续即是预测阶段，这种学习方法也称之为离线学习(Offline Learning)。离线学习方法在小规模数据上取得了巨大的成就，但是当数据规模大时，这种方法计算复杂度

高、响应慢，无法用于实时性要求高的学习场景中。

与传统批量式数据不同，流式数据^[72]是一种动态性数据，典型例子如传感器数据、社交信息数据、视频数据等等。流式数据具有实时性、无限性特点，离线学习方法并不适用。为此，研究人员提出了一种新的学习方法：在线学习^[73]，也被称之为“增量学习”或“适应性学习”。在线学习方法可以顺序实时地接收训练数据，每接收一次训练样本，模型就会对它进行预测，同时更新当前模型，然后再处理下一个样本。在线学习方法的优势在于不需要计算机存储所有的训练数据，而且模型具有时效性，能够不断更新，适应环境动态的变化。下图 3.1 比较了在线学习和离线学习的学习流程。

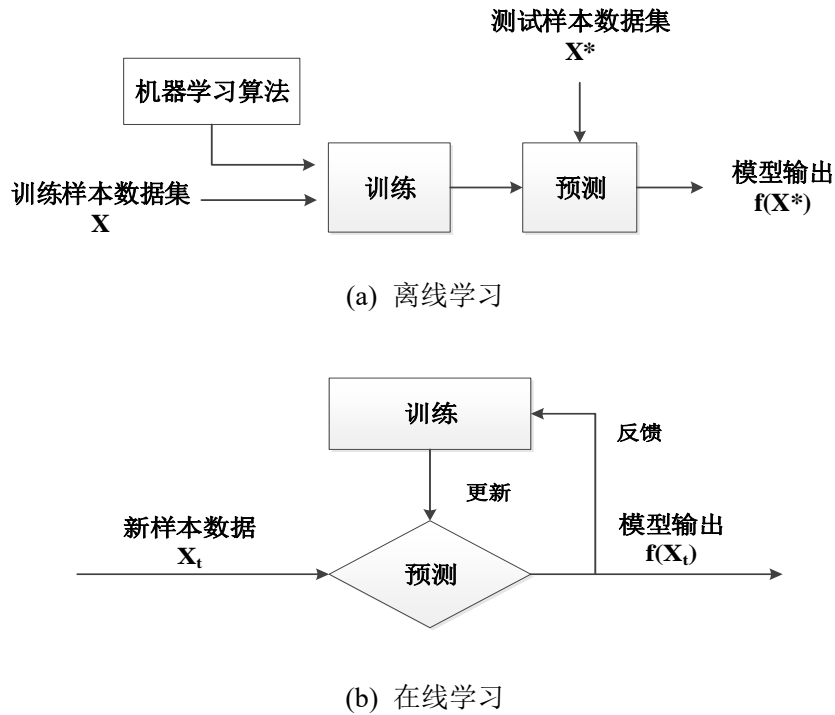


图 3.1 离线学习和在线学习流程比较

Figure 3.1 Comparison between offline learning and online learning process

针对室内位置指纹定位问题，RSS 特征是一种典型的具有时间属性的流式数据，它随着时间的变化逐步到达，而且新数据和旧数据还存在着较大差异性。这种情况下，如果模型不进行更新，那么随着时间的推移，RSS 特征不断变化，模型的性能将不断下降。要解决这个问题，如果采用批量式的离线学习方法，将新增数据与旧数据合并后重新训练学习模型，会导致样本集过大而消耗过多的时间

和存储空间。因此,本文将引入增量式学习方法解决这个问题,使定位模型能够体现环境的动态变化,具有时效性优势。

3.2 极速学习机理论

本节首先介绍一种有监督的单隐层神经网络模型——极速学习机,然后针对极速学习机无法利用无标记数据学习和不具有时效性机制的缺陷分别介绍本文引入的半监督极速学习机和增量式(在线)极速学习机。

3.2.1 极速学习机

极速学习机(Extreme Learning Machine, ELM)是由南洋理工大学黄广斌等人[1-76]提出的一种快速高效的机器学习方法。ELM 算法属于人工神经网络的范畴,是一种前向单隐层神经网络(Single Hidden Layer Feed-forward Neural Network, SLFN)。具有训练时间短、网络结构简单等特点(图 3.2)。对于一个输入向量 $x \in R^n$ 和具有 L 个隐层节点的 SLFN, 其输出形式定义为下式(3.2-1)。

$$f_L(x) = \sum_{i=1}^L \beta_i G(a_i, b_i, x), a_i \in R^L, b_i \in R, \beta_i \in R^m \quad \dots(3.2-1)$$

其中 $a_i = [a_{i1}, a_{i2}, L, a_{in}]^T$ 表示输入节点与第 i 个隐层节点的权值, b_i 表示第 i 个隐层节点的偏置参数, $G(a_i, b_i, x)$ 是第 i 个隐层节点的输出, $\beta = [\beta_{i1}, \beta_{i2}, L, \beta_{im}]^T$ 表示连接第 i 个隐层节点与输出节点的权值。




图 3.2 单隐层前馈神经网络 SLFN

Figure 3.2 Structure of ELM(Single-hidden layer feed-forward neural network)

选取隐层节点的激活函数(Activation Function)为 $g(x)$ ，通常激活函数 $g(x)$ 选择“Sigmoid”、“Relu”、“RBF”函数等。则：

$$G(\mathbf{a}_i, b_i, \mathbf{x}) = g(\mathbf{a}_i \cdot \mathbf{x} + b_i), \mathbf{a}_i \in R^n, b_i \in R \quad \dots(3.2-2)$$

对于输入的 N 个训练样本数据集 $\{(x_j, t_j) | j=1, 2, \dots, N\}$, $x_j = [x_{j1}, x_{j2}, \dots, x_{jn}]^T$ 。其中， $x_j \in R^n$ 代表输入的信号特征向量， $t_j \in R^n$ 代表样本点对应的物理坐标，则有：

$$G(\mathbf{a}_i, b_i, \mathbf{x}_j) = g(\mathbf{a}_i \cdot \mathbf{x}_j + b_i), \mathbf{a}_i \in R^n, b_i \in R, j=1, 2, L, N \quad \dots(3.2-3)$$

综上，用矩阵表示为

$$\mathbf{H} = \begin{Bmatrix} G(a_1, b_1, x_1) & L & G(a_L, b_L, x_1) \\ & M & O & M \\ G(a_1, b_1, x_N) & L & G(a_L, b_L, x_N) \end{Bmatrix}_{N \times L} \quad \dots(3.2-4)$$

$$\boldsymbol{\beta} = \begin{Bmatrix} \boldsymbol{\beta}_1^T \\ M \\ \boldsymbol{\beta}_L^T \end{Bmatrix}_{L \times m}, \quad \mathbf{T} = \begin{Bmatrix} t_1^T \\ M \\ t_N^T \end{Bmatrix}_{N \times m}$$

根据式 3.2-1，可得

$$\mathbf{H}\boldsymbol{\beta} = \mathbf{T} \quad \dots(3.2-5)$$

此式表示构建的 SLFN 将以零误差训练模型参数。

\mathbf{H} 表示隐层输出矩阵， $\boldsymbol{\beta}$ 表示为输出权值矩阵， \mathbf{T} 表示输出类别矩阵。传统的单隐层神经网络利用梯度下降[77]的方式学习输入权值矩阵、隐节点偏置和输出权值矩阵，但是梯度下降的方式容易出现梯度消失或局部最优等不利情况，而且迭代优化求解的过程导致了学习速度缓慢。相比于传统的单隐层神经网络学习方法，极速学习机对输入权值矩阵 \mathbf{a}_i 和偏置 b_i 随机赋值，无需在训练过程中调整，只需求解网络输出权值矩阵 $\boldsymbol{\beta}$ 。因此， \mathbf{H} 和 \mathbf{T} 已知，故 $\boldsymbol{\beta}$ 为待求解参数。上述方程可以视为一个线性系统，求解上述方程可通过求解该系统的最小均方误差来实现，即等价于求解式(3.2-6)：

$$\arg \min_{\boldsymbol{\beta}} (\|\mathbf{H}\boldsymbol{\beta} - \mathbf{T}\|) \quad \dots(3.2-6)$$

利用最小二乘方法对上式求解得：

$$\boldsymbol{\beta} = \mathbf{H}^\dagger \mathbf{T} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{T} \quad \dots(3.2-7)$$

其中, \mathbf{H}^\dagger 是 \mathbf{H} 的广义逆矩阵[79]。

因此, 极速学习机算法流程总结如下:

步骤 1: 给定训练样本数据集 $\{(\mathbf{x}_j, t_j) | j=1, 2, \dots, N\}$, $\mathbf{x}_j = [x_{j1}, x_{j2}, \dots, x_{jn}]^T$;

步骤 2: 随机设置输入权值矩阵 \mathbf{a}_i 和偏置参数 b_i , 确定隐层节点个数 L , 设定激活函数 $g(x)$;

步骤 3: 计算隐层输出权值矩阵 \mathbf{H} ;

步骤 4: 根据公式 (3.2-7) 计算网络的输出权值矩阵 $\boldsymbol{\beta}$;

步骤 5: 通过 $\boldsymbol{\beta}$ 计算网络最终的输出值 $\mathbf{H}\boldsymbol{\beta}$ 。

3.2.2 半监督极速学习机

位置指纹定位算法为了保证有较好的预测精确度, 需要依赖于大量的训练样本数据, 少量的数据难以得到精确稳定的学习模型。但是大批量的标记数据采集工作需要大量的工作量, 成本很高。为了降低标记指纹采集的工作量, 同时保证定位模型的精度, 本文引入基于极速学习机的半监督学习方法(Semi-supervised ELM, SELM)[80]。SELM 是一种基于 ELM 的扩展方法, 它将标记样本结合无标记样本一起训练, 从而提升模型预测效果, 其主要目标是通过发掘无标记样本的信息来弥补标记样本不足带来的影响。

为了使 SELM 相比于 ELM 取得更好的预测精度, 同时避免过拟合, 提高泛化能力, 根据结构风险最小化理论[81], 模型需要平衡经验风险和学习函数 f 的复杂度。本文根据上文 3.1.2 小节介绍的流形正则化理论, 引入拉普拉斯算子做流形约束。文献[82]中, 使用图的平滑度函数 $S(f)$ 来表示模型复杂性, 定义为:

$$S(f) = \sum_{i \sim j} w_{ij} (f_i - f_j)^2 = \mathbf{f}^T \mathbf{L}_\alpha \mathbf{f} \quad \dots(3.2-8)$$

其中, \mathbf{L}_α 代表图的拉普拉斯算子。根据 3.1.2 小节中分析, $\mathbf{L}_\alpha = \mathbf{D} - \mathbf{W}$, \mathbf{D} 代表对角矩阵, 矩阵分量为 $D_{ij} = \sum_{j=1}^{l+u} \omega_{i,j}$, 其中, w_{ij} 通过高斯分布得到: $w_{ij} = \exp\left(-|x_i - x_j|^2 / 2\delta^2\right)$ 。使用均方损失函数表示模型经验风险, 并平衡学习函

数复杂度，可得下式(3.2-9):

$$\arg \min_f \frac{1}{2} (\|f - T\|^2 + \lambda f^T L_\alpha f) \quad \dots(3.2-9)$$

其中， λ 是流形正则项的惩罚系数。带入 $H\beta = f$ 可得：

$$\arg \min_f l(\beta) = \arg \min_f \frac{1}{2} (\|JH\beta - T\|^2 + \lambda (H\beta)^T L_\alpha (H\beta)) \quad \dots(3.2-10)$$

矩阵 H 可以通过公式 3.4 得出，维度为 $(l+u) \times L$ 。为计算简便，令 $J = \text{diag}(1, 1, \dots, 0, 0)$ ，1 的个数为标记数据个数 l ，0 的个数为无标记数据个数 u 。

对公式(3.2-10)进行求导如下：

$$\frac{\partial l}{\partial \beta} = 0 \Rightarrow (JH\beta - T)^2 + \lambda (H\beta)^T L_\alpha H = 0 \quad \dots(3.2-11)$$

最终可求得 SELM 模型表达式为：

$$\beta = (H^T JH + \lambda H^T L_\alpha H)^{-1} H^T J T \quad \dots(3.2-12)$$

当式 3.2-12 中 λ 被置为 0，则意味着非标定样本数据被忽略，则 β 退化为式 3.2-7，此时就是监督学习下的极速学习机模型。

3.2.3 增量式极速学习机

增量式学习方法采用最新到达的数据对预测模型进行更新，能更好体现预测模型的结构调整。对于监督式位置指纹定位方法，为了获得增量式实时学习效果，当新增训练数据 \mathbf{X}^* ，可以将其与旧的训练样本数据组成一个新的训练集，重新按照图 2.4 的训练过程获得模型。但是这种做法存在严重的弊端：对旧样本重复计算造成模型的时间和空间复杂度不断增加，不但模型运算愈加缓慢，而且普通移动终端也没有足够空间存储不断增长的样本数据，因此这种方法在实际应用中不具有可行性。为此，文献[83]提出了一种增量式 ELM(Online Sequential ELM, OSELM)学习算法，用实时到来的新数据 \mathbf{X}^* 贡献的 $\Delta\beta$ 去修正已有的学习模型 β_0 ，从而得到新的学习模型 β^* 。OSELM 的关键优势在于模型的增量部分 $\Delta\beta$ 仅依赖于新样本数据 \mathbf{X}^* ，不依赖于旧样本数据，从而大大降低了模型训练的

时空复杂度，保证了模型的实用性。增量式学习模型框架如下式：

$$\boldsymbol{\beta}^* = \boldsymbol{\beta}_0 + \Delta \boldsymbol{\beta}(\mathbf{X}^*) \quad \dots(3.2-13)$$

具体而言，OSELM 方法训练过程可分为两个子过程：

初始训练过程：OSELM 会利用已有标记样本 \mathbf{X}_0 训练出初始模型 $\boldsymbol{\beta}_0$ ，根据公式(3.2-7)，不妨假设得到的初始学习模型为

$$\boldsymbol{\beta}_0 = \mathbf{K}_0^{-1} \mathbf{H}_0^T \mathbf{T}_0 \quad \dots(3.2-14)$$

其中 $\mathbf{K}_0 = \mathbf{H}_0^T \mathbf{H}_0$ 。

增量训练过程：当新增 N_1 个样本点数据集 $\mathbf{X}_1 = \{(x_i, t_i)\}_{i=N_0+1}^{N_0+N_1}$ ，则学习模型通过下式求解：

$$\arg \min_{\boldsymbol{\beta}} \left(\left\| \begin{bmatrix} \mathbf{H}_0 \\ \mathbf{H}_1 \end{bmatrix} \boldsymbol{\beta} - \begin{bmatrix} \mathbf{T}_0 \\ \mathbf{T}_1 \end{bmatrix} \right\| \right) \quad \dots(3.2-15)$$

求解上式可得：

$$\boldsymbol{\beta}_1 = \mathbf{K}_1^{-1} \begin{bmatrix} \mathbf{H}_0 \\ \mathbf{H}_1 \end{bmatrix}^T \begin{bmatrix} \mathbf{T}_0 \\ \mathbf{T}_1 \end{bmatrix} \quad \dots(3.2-16)$$

其中 $\mathbf{K}_1 = \begin{bmatrix} \mathbf{H}_0 \\ \mathbf{H}_1 \end{bmatrix}^T \begin{bmatrix} \mathbf{H}_0 \\ \mathbf{H}_1 \end{bmatrix}$ 。联立(3.2-14)和(3.2-16)，得到 $\boldsymbol{\beta}_1$ 的迭代公式如下所示：

$$\boldsymbol{\beta}_1 = \boldsymbol{\beta}_0 + \mathbf{K}_1^{-1} \mathbf{H}_1^T (\mathbf{T}_1 - \mathbf{H}_1 \boldsymbol{\beta}_0) \quad \dots(3.2-17)$$

$$\mathbf{K}_1 = \mathbf{K}_0 + \mathbf{H}_1^T \mathbf{H}_1 \quad \dots(3.2-18)$$

上式(3.2-17)正符合(3.2-13)的增量模型框架， $\boldsymbol{\beta}_1$ 的计算基于 $\boldsymbol{\beta}_0$ ，不需要再将所有的旧样本数据重新进行计算，从而大大减小计算量。另外，增量部分 $\mathbf{K}_1^{-1} \mathbf{H}_1^T (\mathbf{T}_1 - \mathbf{H}_1 \boldsymbol{\beta}_0)$ 体现出新增的样本信息 $(\mathbf{H}_1, \mathbf{T}_1)$ 对学习模型的修正。

为了使上式能够运用在多次更新计算中，需要将其扩展为递归式：

$$\mathbf{K}_{k+1} = \mathbf{K}_k + \mathbf{H}_{k+1}^T \mathbf{H}_{k+1} \quad \dots(3.2-19)$$

$$\boldsymbol{\beta}_{k+1} = \boldsymbol{\beta}_k + \mathbf{K}_{k+1}^{-1} \mathbf{H}_{k+1}^T (\mathbf{T}_{k+1} - \mathbf{H}_{k+1} \boldsymbol{\beta}_k) \quad \dots(3.2-20)$$

3.3 终端自适应的在线定位方法

3.3.1 方法原理

上文所述的几种基于极速学习机的方法均适用于室内定位领域。

对于 ELM 算法, 需要事先利用手机等终端采集一批标定位置的信号数据样本集 (\mathbf{X}, \mathbf{T}) , 其中 \mathbf{X} 为采集的 RSS 特征矩阵, \mathbf{T} 为标记的位置矩阵。然后离线训练得到隐层输出权值矩阵 $\boldsymbol{\beta}$, 接着在在线预测阶段, 终端在待定位的位置采集 RSS 特征数据, 利用 $\mathbf{T} = \mathbf{H}\boldsymbol{\beta}$ 即可计算出预测的定位结果。SELM 和 OSELM 分别从不同角度对 ELM 进行了改进优化。一方面, 在实际室内环境中, 人工采集标记的信号数据样本集的成本很高, 而无标记的信号数据却很容易获得, 用户在定位区域内, 只要使用手机软件启动相关位置服务, 就可以采集到无标记的信号数据。为此, SELM 充分利用训练数据结构性平滑的特点, 将无标记的样本数据加入到训练样本集, 丰富了训练样本集, 提高了模型精度。另一方面, 由于无线信号在时间轴上具有高动态性特点, 因此 RSSI 指纹数据库的时效性问题将导致定位模型漂移, 影响定位精度。为此, OSELM 通过新增训练样本数据对模型持续进行迭代更新, 有效保证了模型的时效性, 从而提升了定位精度。但是上面这三种模型仍具有以下问题:

(1) SELM 算法没有解决模型的时效性问题, 随着时间的推移, 模型存在漂移, 导致定位精度不断下降; 而 OSELM 算法没有解决标记数据采集成本高的问题, 实用性低。

(2) 利用手机等终端定位时, 存在设备的差异性问题。SELM 算法没有考虑这一点, 模型训练完毕之后, 不同终端使用完全相同的模型。因此根据 2.3.3.2 小节的分析, 即使在同一位置, 由于不同终端设备采集的无线信号数据也可能具有明显差异, 导致不同终端的定位结果差异性较大, 定位可信度差。OSELM 虽然能够利用终端采集的数据更新模型, 使模型逐渐适配于该终端, 但这种标记的增量数据采集成本过高, 不具有实际可用性。

为了解决上述问题, 本文在前面三种算法的基础上提出一种半监督增量式极速学习机(Semi-supervised Online Sequential ELM, SOSELM), 该学习机不仅继承了 ELM 算法的优点, 同时利用无标记的信号数据对模型进行迭代更新, 具有半

监督学习和增量学习能力，从而解决模型的时效性问题和数据标定问题，而且模型在更新阶段使用的是当前终端采集的信号数据，这种数据反映了当前终端的信号采集性能和信号描述的个性化特点，具有终端差异性。随着时间的推移，当前终端学习的模型将越来越适配于该终端，即模型具有自适应能力，定位精度将不断提高。

终端自适应的在线定位方法原理如下图 3.3 所示。

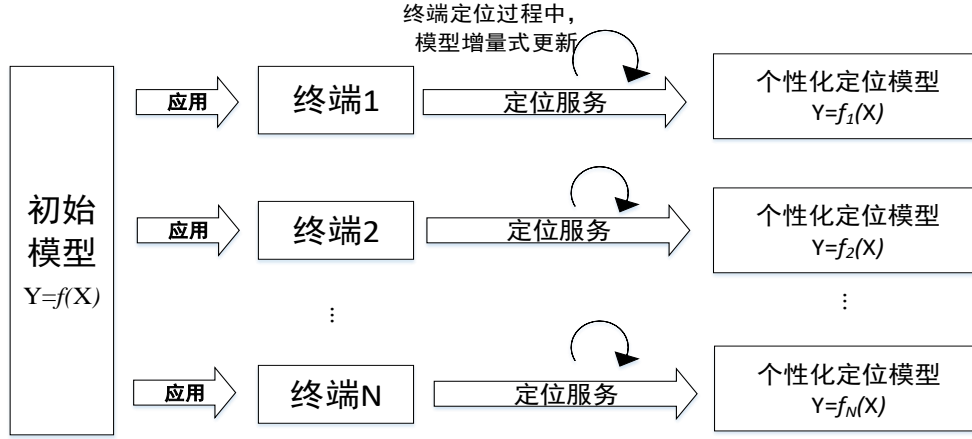


图 3.3 终端自适应的在线定位方法原理图

Figure 3.3 Diagram of online terminal adaptive localization method

3.3.2 半监督增量式极速学习机

本文通过修改 SELM 算法结合流形正则化方法提出半监督增量式极速学习机(SOSELM)。

为计算方便，令 $\mathbf{K} = (\mathbf{H}^T \mathbf{J} \mathbf{H} + \lambda \mathbf{H}^T \mathbf{L} \mathbf{H})$ ，则表达式(3.2-12)转化为：

$$\boldsymbol{\beta} = \mathbf{K}^{-1} \mathbf{H}^T \mathbf{J} \mathbf{T} \quad \dots(3.3-1)$$

现假设初始一批训练样本集为 $\mathcal{S}_0 = \{(x_i, t_i) \text{ or } x'_i\}_{i=1}^{N_0}$ ，其中包括标记样本集 (x_i, t_i) 与无标记样本集 x'_i 。为了使训练误差最小化，由式(3.2-12)可得首次训练的输出权值矩阵为：

$$\boldsymbol{\beta}_0 = \mathbf{K}_0^{-1} \mathbf{H}_0^T \mathbf{J}_0 \mathbf{T}_0 \quad \dots(3.3-2)$$

其中， $\mathbf{K}_0 = (\mathbf{H}_0^T \mathbf{J}_0 \mathbf{H}_0 + \lambda \mathbf{H}_0^T \mathbf{L}_{\mathcal{S}_0} \mathbf{H}_0)$ 。

假设现在得到一批新的样本数据集 $\mathcal{S}_1 = \{(x_i, t_i) \text{ or } x'_i\}_{i=N_0+1}^{N_0+N_1}$ ，其中也包括标记

样本集和无标记样本集。根据式(3.3-1)，在融合旧样本和新样本的数据集下，新的输出权值矩阵可表示为：

$$\beta_1 = K_1^{-1} \begin{pmatrix} H_0 \\ H_1 \end{pmatrix}^T \begin{pmatrix} J_0 & \\ & J_1 \end{pmatrix} \begin{pmatrix} T_0 \\ T_1 \end{pmatrix} \quad \dots(3.3-3)$$

其中：

$$K_1 = \begin{pmatrix} H_0 \\ H_1 \end{pmatrix}^T \begin{pmatrix} J_0 & \\ & J_1 \end{pmatrix} \begin{pmatrix} H_0 \\ H_1 \end{pmatrix} + \lambda \begin{pmatrix} H_0 \\ H_1 \end{pmatrix}^T L_{\mathbb{N}_0 \cup \mathbb{N}_1} \begin{pmatrix} H_0 \\ H_1 \end{pmatrix} \quad \dots(3.3-4)$$

$$L_{\mathbb{N}_0 \cup \mathbb{N}_1} = \begin{pmatrix} L_{\mathbb{N}_0} + D_{\mathbb{N}_0 \mathbb{N}_1} & -W_{\mathbb{N}_0 \mathbb{N}_1} \\ -W_{\mathbb{N}_0 \mathbb{N}_1}^T & L_{\mathbb{N}_1} + D_{\mathbb{N}_0 \mathbb{N}_1} \end{pmatrix} \quad \dots(3.3-5)$$

对于式(3.3-3)，由 3.2.2 节可知， J_0 和 J_1 都是形如 $J = \text{diag}(1, 1, \dots, 0, 0)$ 的对角矩阵，1 的个数等于有标记的数据个数，0 的个数等于无标记数据个数。 T_0 和 T_1 是样本集的位置坐标矩阵，如果是无标记数据集，位置坐标未知，为了满足矩阵运算的维度要求，需要填充值，使得 $\begin{pmatrix} T_0 \\ T_1 \end{pmatrix}$ 矩阵的维数为 $(N_0 + N_1) \times m$ 。填充的数值可以随意设置，由于矩阵 J 的作用，填充的数值并不会影响预测结果。 H_0 和 H_1 可根据 3.2.1 节介绍的内容直接计算求得。对于式(3.3-5)，出现了融合旧样本数据和新样本数据的参数 $D_{\mathbb{N}_0 \mathbb{N}_1}$ 、 $W_{\mathbb{N}_0 \mathbb{N}_1}$ 、 $W_{\mathbb{N}_0 \mathbb{N}_1}^T$ 。这些项要求我们需要再次计算旧样本数据，这和我们在 OSELM 中的分析思路相违背，会造成时间和计算资源的浪费。对此，从(3.2-9)式出发，我们通过最小化均方损失函数和平滑度惩罚来计算输出权值矩阵，因此忽略 $D_{\mathbb{N}_0 \mathbb{N}_1}$ 、 $W_{\mathbb{N}_0 \mathbb{N}_1}$ 、 $W_{\mathbb{N}_0 \mathbb{N}_1}^T$ 项对最终结果将产生微弱的影响但将极大地减少计算量。此时，(3.3-5)转化为：

$$L_{\mathbb{N}_0 \mathbb{N}_1} = \begin{pmatrix} L_{\mathbb{N}_0} & \\ & L_{\mathbb{N}_1} \end{pmatrix} \quad \dots(3.3-6)$$

将(3.3-6)带入(3.3-4)中，求解得 K_1 的表达式：

$$\begin{aligned}
 \mathbf{K}_1 &= \begin{pmatrix} \mathbf{H}_0 \\ \mathbf{H}_1 \end{pmatrix}^T \begin{pmatrix} \mathbf{J}_0 & \\ & \mathbf{J}_1 \end{pmatrix} \begin{pmatrix} \mathbf{H}_0 \\ \mathbf{H}_1 \end{pmatrix} + \lambda \begin{pmatrix} \mathbf{H}_0 \\ \mathbf{H}_1 \end{pmatrix}^T \begin{pmatrix} \mathbf{L}_{\mathbf{N}_0} & \\ & \mathbf{L}_{\mathbf{N}_1} \end{pmatrix} \begin{pmatrix} \mathbf{H}_0 \\ \mathbf{H}_1 \end{pmatrix} \\
 &= \mathbf{H}_0^T \mathbf{J}_0 \mathbf{H}_0 + \lambda \mathbf{H}_0^T \mathbf{L}_{\mathbf{N}_0} \mathbf{H}_0 + \mathbf{H}_1^T \mathbf{J}_1 \mathbf{H}_1 + \lambda \mathbf{H}_1^T \mathbf{L}_{\mathbf{N}_1} \mathbf{H}_1 \quad \dots(3.3-7) \\
 &= \mathbf{K}_0 + \mathbf{H}_1^T (\mathbf{J}_1 + \lambda \mathbf{L}_{\mathbf{N}_1}) \mathbf{H}_1
 \end{aligned}$$

另外,

$$\begin{aligned}
 \begin{pmatrix} \mathbf{H}_0 \\ \mathbf{H}_1 \end{pmatrix}^T \begin{pmatrix} \mathbf{J}_0 & \\ & \mathbf{J}_1 \end{pmatrix} \begin{pmatrix} \mathbf{T}_0 \\ \mathbf{T}_1 \end{pmatrix} &= \mathbf{H}_0^T \mathbf{J}_0 \mathbf{T}_0 + \mathbf{H}_1^T \mathbf{J}_1 \mathbf{T}_1 \\
 &= \mathbf{K}_0 \mathbf{K}_0^{-1} \mathbf{H}_0^T \mathbf{J}_0 \mathbf{T}_0 + \mathbf{H}_1^T \mathbf{J}_1 \mathbf{T}_1 \quad \dots(3.3-8) \\
 &= \mathbf{K}_0 \boldsymbol{\beta}_0 + \mathbf{H}_1^T \mathbf{J}_1 \mathbf{T}_1
 \end{aligned}$$

将式(3.3-7)和(3.3-8)带入(3.3-3), 求得 $\boldsymbol{\beta}_1$ 的迭代式:

$$\begin{aligned}
 \boldsymbol{\beta}_1 &= \mathbf{K}_1^{-1} (\mathbf{K}_0 \boldsymbol{\beta}_0 + \mathbf{H}_1^T \mathbf{J}_1 \mathbf{T}_1) \\
 &= \mathbf{K}_1^{-1} \{ [\mathbf{K}_1 - \mathbf{H}_1^T (\mathbf{J}_1 + \lambda \mathbf{L}_{\mathbf{N}_1}) \mathbf{H}_1] \boldsymbol{\beta}_0 + \mathbf{H}_1^T \mathbf{J}_1 \mathbf{T}_1 \} \quad \dots(3.3-9) \\
 &= \boldsymbol{\beta}_0 + \mathbf{K}_1^{-1} \mathbf{H}_1^T [\mathbf{J}_1 \mathbf{T}_1 - (\mathbf{J}_1 + \lambda \mathbf{L}_{\mathbf{N}_1}) \mathbf{H}_1 \boldsymbol{\beta}_0]
 \end{aligned}$$

至此, 我们得到了形如(3.2-13)的基于半监督样本的增量式模型。与 OSELM 类似, 上式可以扩展为递归表达式:

$$\boldsymbol{\beta}_{k+1} = \boldsymbol{\beta}_k + \mathbf{K}_{k+1}^{-1} \mathbf{H}_{k+1}^T [\mathbf{J}_{k+1} \mathbf{T}_{k+1} - (\mathbf{J}_{k+1} + \lambda \mathbf{L}_{\mathbf{N}_{k+1}}) \mathbf{H}_{k+1} \boldsymbol{\beta}_k] \quad \dots(3.3-10)$$

$$\mathbf{K}_{k+1} = \mathbf{K}_k + \mathbf{H}_{k+1}^T (\mathbf{J}_{k+1} + \lambda \mathbf{L}_{\mathbf{N}_{k+1}}) \mathbf{H}_{k+1} \quad \dots(3.3-11)$$

初始样本集利用(3.3-2)进行模型学习训练之后, 对于每次新增的标记或无标记样本数据, 通过 SOSELM 方法进行模型的实时修正。因为每次只计算新增的样本数据, 所以训练速度大大提高。同时该方法是基于半监督学习的增量式学习方法, 既保证了模型的时效性, 又极大地减小了数据标记的工作量。

综上, SOSELM 的流程图如图 3.4 所示。

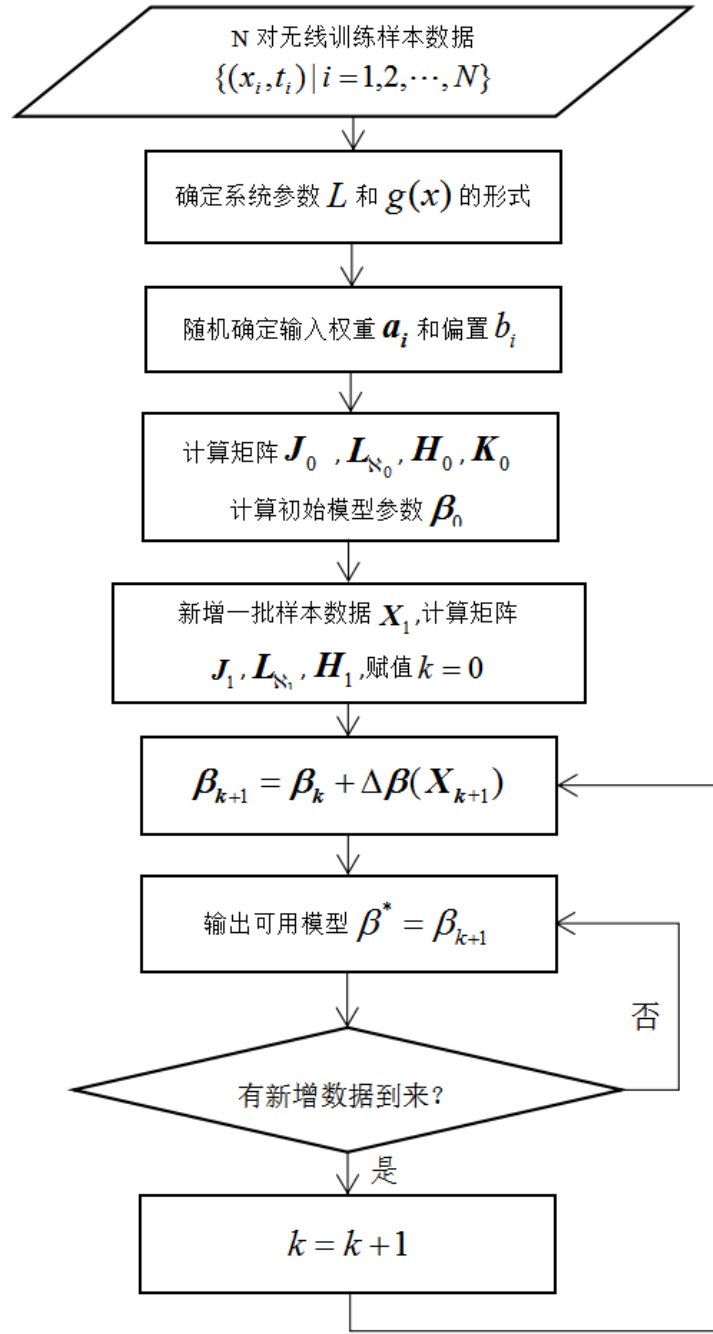


图 3.4 SOSELM 算法流程图

Figure 3.4 Flowchart of SOSELM algorithm

训练过程总结如下：对于一批训练数据集，包括标记数据集 $\{(x_i, t_i) | x_i \in R^n, t_i \in R^m, i = 1, 2, \dots, N_l\}$ 和未标记数据集 $\{x'_i | x'_i \in R^n, i = 1, 2, \dots, N_u\}$ 。

先确定系统参数，包括隐层节点个数 L ，平滑度惩罚系数 λ ，激活函数形式 $g(x)$ 。

根据文献[84]，对于实际问题，ELM 的隐层节点个数 L 一般取足够多即可（如

1000)，本文实验取 $L=1000$ 。接下来，训练过程将分为两步：

(1) 初始阶段：利用少量的输出训练样本集 $\mathfrak{N}_0 = \{(x_i, t_i) \text{ or } x'_i\}_{i=1}^{N_0}$ 来计算初始阶段的输出权值矩阵 β_0 ，具体如下：

- a) 通过随机方式给输入权值 a_i 和偏置 b_i 赋值， $i = 1, 2, \dots, L$ ；
- b) 计算初始矩阵 J_0 ，图的拉普拉斯矩阵 $L_{\mathfrak{N}_0}$ 以及隐层输出矩阵 H_0 ；
- c) 计算矩阵 K_0 和输出权值矩阵 β_0 。

(2) 增量阶段：当新增一批样本数据 $\mathfrak{N}_{k+1} = \{(x_i, t_i) \text{ or } x'_i\}_{i=N_k+1}^{N_k+N_{k+1}}$ 时，将迭代计算输出权值 β_{k+1} ，具体如下：

- a) 统计新增样本中标记数据个数 l 和未标记数据个数 u ，然后计算矩阵 J_{k+1} 、 $L_{\mathfrak{N}_{k+1}}$ 和 H_{k+1} ；
- b) 利用式(3.3-10)计算更新的输出权值矩阵 β_{k+1} 。

3.4 实验验证及分析

为了验证本文提出的 SOSELM 模型的有效性，本节进行实验仿真。算法运行环境为 MATLAB R2013a, Windows 10 操作系统，硬件环境为 Inter(R) Core(TM) i7-4790 CPU @ 3.60GHZ。

实验分为两部分：第一部分基于 SinC 函数模拟数据比较 SOSELM 模型算法与其他模型算法的预测精度；第二部分基于实际环境中采集的定位样本数据比较不同模型的实际定位精度。观察各模型在实际定位数据集上的表现，并且比较 SOSELM 模型随着时间推移定位精度的变化情况，然后将不同终端的测试数据与不同终端的个性化模型进行交叉测试，验证本文提出增量式室内定位方法是否有效解决了设备差异性问题的，具有终端自适应能力。

3.4.1 基于 SinC 函数模拟数据集的算法对比实验

3.4.1.1 SinC 函数模拟数据集

SinC 函数^[85]是描述物理现象的一个重要函数，广泛应用于信号处理领域。sinc 函数在数学上的非归一化定义为：

$$f(x) = \begin{cases} \frac{\sin x}{x}, & x \neq 0 \\ 1, & x = 0 \end{cases} \quad \dots(3.4-1)$$

实验中 x 取 5000 个范围在 $(-10, 10)$ 之间的随机值。为了更好地观察比较不同模型的回归能力，在获取训练样本集时，给标定值加入一定的噪声干扰。本实验中，噪声干扰取 $(-0.2, 0.2)$ 之间的随机数。下图显示了带噪声的标定值与真实值的关系。




图 3.5 带噪声标定值与真实值的关系图

Figure 3.5 Relationship between labels with noise and true labels

3.4.1.2 算法参数设置

(1) 首先设置隐层节点个数 L 、输入层到隐层的权值矩阵 \mathbf{a} 、偏置矩阵 \mathbf{b} 以及神经网络节点激活函数 $g(x)$ 。隐层节点个数 L 取值 1000。矩阵 \mathbf{a} 和 \mathbf{b} 分别定义如下：

$$\mathbf{a} = \text{rand}(L, N) \times 2 - 1, \mathbf{a}_i \in \mathbf{a}^N, i = 1, 2, \dots, N \quad \dots(3.4-2)$$

$$\mathbf{b} = \text{rand}(L, 1), \mathbf{b}_i \in \mathbf{b}^L, i = 1, 2, \dots, L \quad \dots(3.4-3)$$

其中， N 表示训练样本数量， $\text{rand}(m, n)$ 函数用于随机生成 $(0, 1)$ 区间均匀分布的 $m \times n$ 矩阵。激活函数 $g(x)$ 选取 Sigmoid 函数，定义如下：

$$g(x) = \frac{1}{1 + e^{-x}} \quad \dots(3.4-4)$$

(2) SOSELM 是一种基于半监督学习的极速学习机，模型中的平滑度惩罚

系数 λ 体现了模型经验风险和学习函数 f 的复杂度之间的均衡关系。 λ 值的大小将直接关系到模型的回归性能, 因此需要对 λ 进行调优。实验采用 SinC 模拟数据集, λ 值以步长 0.05 从 0 遍历到 1, 标定的训练数据量取 100 个, 无标定的数据量分别取 300、500、700、900、1100 个, 对 5 次预测的均方根误差(Root Mean Square Error, RMSE)取均值, 作为每个 λ 的预测误差。RMSE 用来衡量观测值和真值之间的偏差, 假设观测次数为 n , 第 t 次的观测值为 \hat{y}_t , 真实值为 y_t , 则 RMSE 定义如下:

$$RMSE = \sqrt{\frac{\sum_{t=1}^n (\hat{y}_t - y_t)^2}{n}} \quad \dots(3.4-5)$$

实验结果如图 3.6 所示。可以看出, 预测误差与 λ 值近似为凸函数关系, 当取 $\lambda = 0.35$ 时, 模型有最优的预测误差。




图 3.6 模型预测均方根误差与 λ 的关系

Figure 3.6 Test error of different λ

3.4.1.3 SOSELM 与其他算法对比

为了验证本文提出的 SOSELM 算法的有效性, 本文选取了 ELM 算法、BP 神经网络算法、支持向量机算法(SVM)三种典型的算法与 SOSELM 算法进行对比。从生成的 5000 个训练样本数据集中, 随机取 500 个数据作为初始训练样本数据, 其中标定数据量 and 无标定数据量比例为 1:1。模型参数 λ 根据 3.4.1.2 节实验结果取值 0.35。对于 SOSELM 的增量部分, 每次取 500 个无标定数据进行增量更新。实验结果如下图 3.7 所示。分析可知, SOSELM 与 ELM 具有相近的均

方根误差，且都明显优于另外两种方法；且 SOSELM 优于 ELM 算法，这是由于本文方法基于 ELM，保留了 ELM 算法的优势，同时基于无标定的数据对模型进行增量更新，使预测精度比 ELM 模型高。对于表现较好的 SOSELM 算法和 ELM 算法，它们在 SinC 数据集上的回归分布如图 3.8 所示。

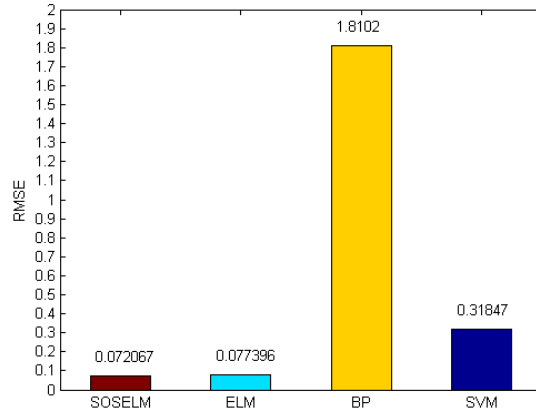


图 3.7 各算法模型在 SinC 数据集下的预测误差比较

Figure 3.7 Comparison of test error in four algorithms by using SinC dataset




图 3.8 SOSELM 模型与 ELM 模型的回归分布

Figure 3.8 Distribution of SOSELM and ELM

3.4.2 基于定位数据集的算法对比实验

3.4.2.1 蓝牙定位数据集

实验数据采集场景设于某研究所的二楼展厅。该实验覆盖范围长约 52.99m，

宽约 8.53m，总体布局如下图 3.9 所示。为了处理不同的采集设备带来的信号差异，本文使用了 4 种不同的智能终端：华为荣耀 6，红米 note3，魅族 Pro5，Vivo X9I。在环境中较为均匀地部署了 25 个 iBeacon 蓝牙信号基站。整个数据采集过程时间跨度为 7 周，每周固定时间采集一次数据。在该实验场景下，手持多种终端设备在环境中缓慢匀速行走采集数据，最终采集到 10434 条有效数据。





图 3.9 定位数据集采集和算法测试场景示意图

Figure 3.9 Scene of training data calibrating and algorithm testing

3.4.2.2 模型参数设置

隐层节点个数 L 、输入层到隐层的权值矩阵 \mathbf{a} 、隐层到输出层的偏置矩阵 \mathbf{b} 以及神经网络节点激活函数 $g(\mathbf{x})$ 的设置与 3.4.1.2 小节相同，无需改变。由于 SinC 样本集和实际定位样本集满足的分布不同，因此无标记样本对模型学习能力的改进程度是不同的，因此不同样本集下需要对 SOSELM 的平滑度惩罚系数 λ 分别进行调优。与 3.4.1.2 小节类似，本小节利用标定样本和无标定样本对 λ 进行调优。实验采用第一周采集的多个手机合并数据集（共 1810 条有效数据）进行调参， λ 值以步长 0.05 从 0 遍历到 1，标定的训练数据量取 500 个，无标定的训练数据量取 500、700、900、1100、1300 个，对 5 次预测的 RMSE 取均值，作为每个 λ 的均方根误差。实验结果如图 3.10 所示。可以看出，当 λ 取值 0.45 时，模型的均方根误差最低。

图 3.10 模型预测均方根误差与 λ 的关系Figure 3.10 Test error of different λ

3.4.2.3 SOSELM 算法与其他算法对比

位置指纹定位算法的有效性需要通过定位精度进行度量。为此，首先定义度量的准则：误差距离 ED 和定位精度 P，如图 3.11 所示。




图 3.11 误差距离 ED 定义

Figure 3.11 Definition of error distance(ED)

假定 Y_{true} 为实际位置， Y_o 为估计位置，两个位置之间的误差距离为 $ED = \sqrt{\|Y_{true} - Y_o\|^2}$ 。设置误差距离阈值 ED_0 ，若 $ED \leq ED_0$ ，则 Y_o 是正确的定位预测；若 $ED > ED_0$ ，则 Y_o 是错误的预测结果。对于 N 条测试样本数据，算法的定位精度定义为：

$$P = \frac{N_{right}}{N} \times 100\% \quad \dots(3.4-6)$$


其中， N_{right} 表示预测正确的样本数量。

为了验证不同指纹模型算法在实际定位数据集上的优劣，我们同样选取 ELM、BP、SVM 算法与 SOSELM 算法进行对比实验。将第一周采集的 1810 条有效数据作为 SOSELM 模型的初始训练样本，同时作为非增量模型的全部训练样本，其中标定数据量和无标定数据量比例为 1:1。模型参数 λ 根据 3.4.2.2 节实验结果取值 0.45。在 SOSELM 模型的增量阶段，分别选取 4 种终端从第 2 周至第 6 周的数据进行增量式学习，最终训练出 4 种不同的 SOSELM 模型。测试数据集选取第 7 周的数据，其中华为荣耀 6 共 338 条有效数据，红米 note3 共 285 条，魅族 Pro5 共 339 条，Vivo X9I 共 340 条。SOSELM 算法的数据集分布情况如下表 3.1 所示，其中，L 表示标记数据个数，U 表示无标记数据个数。不同终端的 SOSELM 模型选用对应终端的测试数据集进行测试。实验结果如下图所示。


表 3.1 SOSELM 算法的数据集在不同终端的分布情况

Table 3.1 Distribution of SOSELM dataset in different terminals


终端品牌	初始阶段 (L:U=1:1)	增量阶段					测试数据 (L:U=0:1)
		第 2 周	第 3 周	第 4 周	第 5 周	第 6 周	
		(L:U=0:1)	(L:U=0:1)	(L:U=0:1)	(L:U=0:1)	(L:U=0:1)	
华为	1810	419	347	435	339	382	338
红米	1810	327	283	332	286	314	285
魅族	1810	418	339	440	340	390	339
vivo	1810	420	343	440	341	387	340



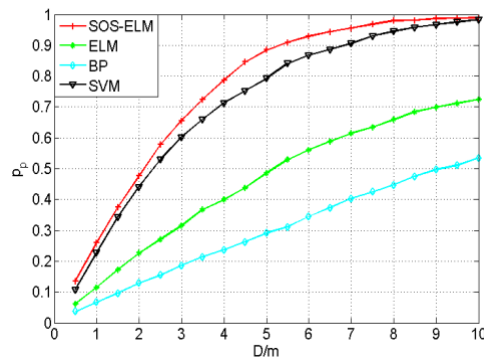
a) 华为手机算法定位精度对比



(b) 红米手机算法定位精度对比



(c)魅族手机算法定位精度对比



(d)vivo 手机算法定位精度对比

图 3.12 各算法在不同定位终端数据集下的定位精度比较

Figure 3.12 Comparison of localization precision of different terminal dataset

其中，横坐标代表误差距离，纵坐标代表定位精度。分析图 3.12 可知，在 4 部手机终端上，SOSELM 算法的整体定位精度都具有优势。在华为、红米和 vivo 手机上，SOSELM 算法整体定位精度均优于其他算法，在误差距离为 5m 时，4 部手机的 SOSELM 定位精度均在 90% 左右，都要明显优于其他 3 种算法。

3.4.2.4 SOSELM 算法的时效性验证

为了验证本文提出的 SOSELM 算法具有时效性优势，本节实验在 3.4.2.3 节实验的基础上，通过比较不同时间 SOSELM 算法的定位精度来测试。在 4 部终端中，随机选取红米 note3 手机终端，对每周采集的数据生成一个 SOSELM 模型。其中，初始训练样本与 4.2.3 节实验相同。增量部分，选取第 2 周到当前周采集到的数据，举例说明：第 1 周 SOSELM 模型的增量数据为空，第 2 周模型的增量数据为第 2 周采集的数据，第 3 周模型的增量数据为第 2、3 周采集的数据，以此类推。测试数据与 4.2.3 节实验相同。实验结果如图 3.13 所示。

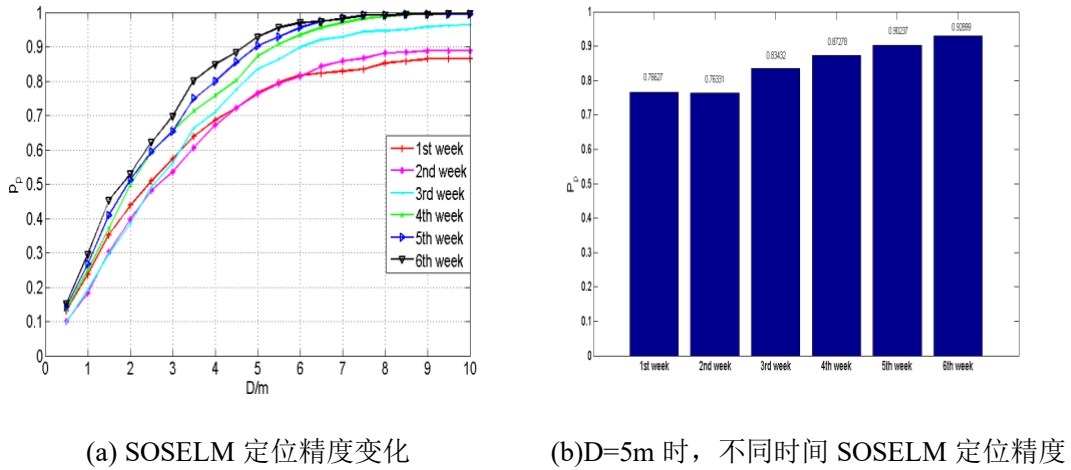


图 3.13 SOSELM 模型随时间推移的定位精度比较

Figure 3.13 Comparison of localization precision in SOSELM over time

其中, 图 3.13(a)图中, 横坐标代表误差距离, 纵坐标代表定位精度。分析图 3.13 可得, 随着时间的推移, SOSELM 算法的定位精度稳步提升, 第 6 周比第 1 周的 SOSELM 模型定位精度提升尤为明显, 在误差距离为 5m 时, 精度提升了约 16%。但是图(b)中, 第 1 周的精度比第 2 周的精度要高约 3%。这是因为, 在基于少量无标记数据的增量式更新下, 模型的定位性能不一定能够得到提升, 甚至由于脏数据的影响, 反而会使得模型精度下降。

3.4.2.5 SOSELM 算法的终端自适应性能验证

为了验证本文提出的 SOSELM 算法有效解决了设备差异性问题, 并具有终端自适应能力。本节在 3.4.2.3 节实验的基础上, 将不同终端的 SOSELM 模型使用非本终端的测试数据集进行测试。实验选取了 Vivo X9I 终端的 SOSELM 模型和红米 note3 终端的 SOSELM 模型。将两个终端的测试数据集交叉测试。实验结果如下图 3.14 所示, 其中, 横坐标代表误差距离, 纵坐标代表定位精度。分析可知, 特定终端模型在其他终端测试数据集上的定位效果明显不如在本终端测试数据集上的定位效果, 这是因为不同终端的 SOSELM 模型具有差异性, 特定终端模型更能反映特定终端采集的数据的分布特点。实际应用中, 终端使用定位服务时会在定位软件中将实时采集的无标定数据进行在线增量式学习, 结合 3.4.2.4 节实验结论, 随着时间推移, 终端的定位模型将越来越能够反映终端无线通讯硬件的特点, 从而有效解决了设备差异性的问题。因此, 本文提出的 SOSELM 算

法实现了模型终端自适应的目标。

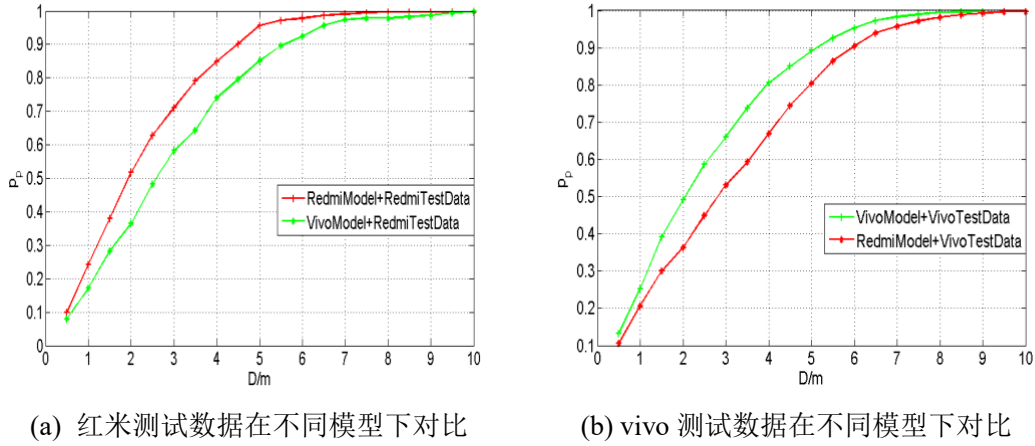


图 3.14 不同测试数据集下，不同终端模型定位精度比较

Figure 3.14 Comparison of localization precision in different terminal model with different test dataset

3.5 本章小结

本章主要是对终端自适应的在线定位算法进行研究。本文引入的算法属于机器学习领域的内容，因此本章首先介绍了机器学习的概念和常见形式，以及离线学习和在线学习，为下文的展开提供理论基础。随后针对基于位置指纹模型的无线信号室内定位方法存在的三个关键问题：数据标定难问题、模型时效性问题和设备差异性问题，本章引入了极速学习机算法，在其基础上进行改进并提出了半监督增量式极速学习机算法。该方法利用终端在定位过程中采集的无标记数据实时更新自身定位模型，有效解决了模型时效性问题以及增量数据标记问题，同时，随着时间的推移，模型越来越反映终端硬件的个性化特点，具有自适应能力。本章最后通过实验证明了本文提出的终端自适应在线定位方法的有效性。

第4章 终端自适应的蓝牙室内定位系统

本文在第三章通过引入极速学习模型提出了终端自适应的在线定位算法，并利用仿真实验验证了本文算法解决数据标定难问题、模型时效性问题和设备差异性问题的有效性。针对以上内容，本章设计并实现了基于低功耗蓝牙 RSSI 信息的室内定位系统。该系统对离线阶段采集的低功耗蓝牙位置指纹数据进行离线初步训练与统一管理，并将核心算法封装成在线定位 SDK，以提供给定位客户端和第三方开发者快速集成使用。

本章第一节首先介绍系统的整体架构，并介绍系统运行的流程；第二节将详细介绍系统各部分的功能模块；第三节展示系统在实际场所定位的效果，并介绍本定位系统的应用案例；第四节进行章节内容小节。

4.1 系统架构与运行流程

本章设计并实现的低功耗蓝牙室内定位系统的组成主要分为三个部分：位置服务云平台、指纹采集客户端和在线定位 SDK。系统框架图如下图 4.1 所示。

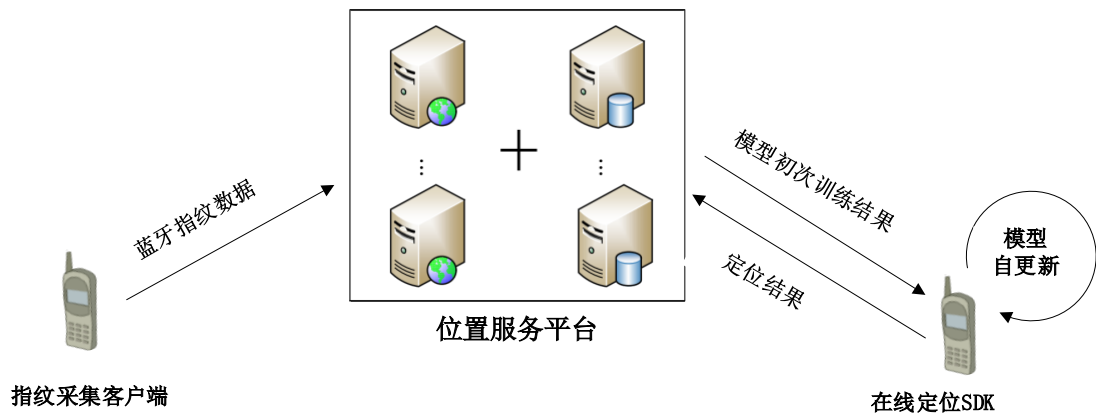


图 4.1 蓝牙室内定位系统框架图

Figure 4.1 Diagram of BLE indoor localization system

如图所示，系统的三个组成部分体现了整个蓝牙定位系统三大功能模块，也体现了系统功能设计中的解耦思想。在软件工程领域，解耦是指降低系统模块之间的依赖性，即耦合度。通过解耦可以让各个模块的修改变化尽可能小地影响其

他模块，能够提高代码复用度，实现业务隔离。解耦是程序设计开发中一个十分重要的思想。

对于本系统而言，三大功能模块分别为位置服务云平台、指纹采集客户端和在线定位 SDK。具体而言，指纹采集客户端是本系统的初始模型数据生成部分，使用此工具进行数据采集属于算法中的离线初始训练阶段。该工具一般由定位系统管理人员或经过指导的人员使用。使用人员在待定位区域按照一定方式采集位置指纹数据，这部分指纹均为有标记的位置指纹，然后工具会对数据进行必要地处理并打包压缩，再上传到位置服务平台。位置服务平台是本蓝牙定位系统的关键组成部分，该平台从功能上可分为数据管理、数据存储和数据训练三个部分。数据管理部分包括指纹数据管理、商场数据管理、用户数据管理等；数据存储包括指纹数据存储、地图信息存储、模型信息存储等；数据训练主要是对指纹采集工具上传的数据进行模型初始训练，得到场所的初始模型，然后分发给各定位终端 SDK。在线定位 SDK 是本系统的核心算法部分，一般集成到终端的定位软件上，SDK 对外提供定位接口。用户使用终端的定位软件定位时，存在两种形式：用户指定当前场所和不指定当前场所，对于后者，SDK 需要调用场所自动识别模块判断当前建筑物。得到当前场所信息之后，如果该终端是首次开始定位，则 SDK 从位置服务平台拉取当前场所的初始定位模型，然后用户终端在定位服务过程中，将实时采集到无标记的蓝牙指纹信息，SDK 将根据当前模型和新数据进行自适应算法更新，并将更新的算法模型持久化到本地存储；如果该终端不是首次定位，则可以直接从本地获取模型信息，开启定位。

系统整体工作流程如下：

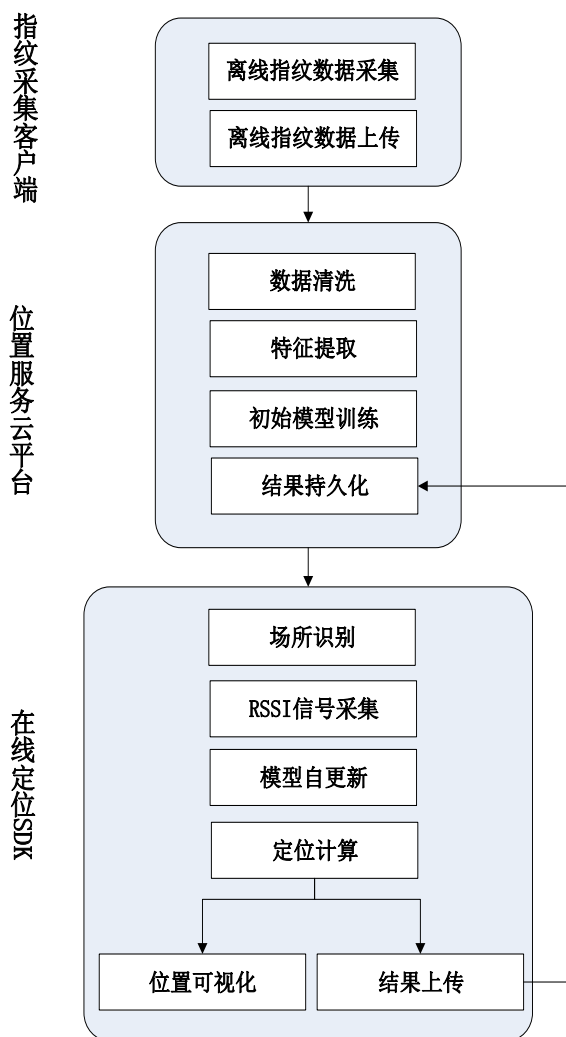


图 4.2 蓝牙室内定位系统流程

Figure 4.2 Process of BLE indoor localization system

根据图 4.2，首先使用指纹采集客户端进行离线指纹采集，然后数据压缩上传到位置服务平台，平台进行数据特征提取，并利用 SOSELM 模型进行模型无增量的初始学习，得到该场所的定位模型。然后在在线定位阶段，客户端首先判断当前定位场所，之后从位置服务平台获取模型，利用实时采集的蓝牙数据进行模型自更新训练，并得到定位结果。定位结果一方面在用户终端进行位置可视化展示，一方面上传到服务器进行存储。

4.2 系统具体设计

整个蓝牙定位系统由三个部分组成，包括指纹采集客户端、位置服务云平台

和在线定位 SDK，下面分别对三部分的设计进行介绍。

4.2.1 指纹采集客户端

指纹采集客户端用于采集定位区域的低功耗蓝牙的指纹信息，主要功能模块有：用户登录模块、用户场景获取模块、场景地图更新模块、指纹数据更新模块、指纹数据采集模块、指纹数据上传模块。模块示意图如图 4.3 所示。下面将对每个模块一一进行介绍。

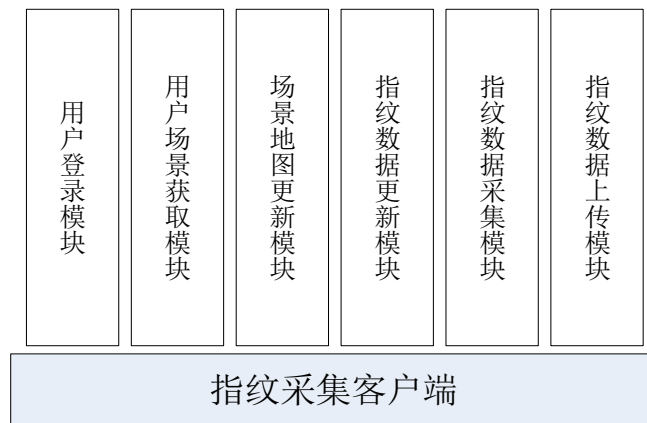


图 4.3 指纹采集客户端功能模块示意图

Figure 4.3 Diagram of function modules in fingerprint acquisition client

用户登录模块：不同大厦的指纹数据是属于第三方开发者的隐私数据，因此每个开发者只能获取自己在位置服务平台注册和上传的场景数据。本模块与位置服务平台服务器通过 **https** 协议接口进行通信，同时基于严格的权限机制控制用户的安全登录。

用户场景获取模块：登录客户端之后，本模块将从位置服务平台服务器拉取当前用户注册的所有的场景信息。一般而言，开发者要采集一个新大厦的指纹数据时，需要先登录位置服务平台进行大厦注册，上传大厦 ID、定位场景地图等信息。然后利用本模块即可获取注册的大厦信息。

场景地图更新模块：对 **RSSI** 信号特征进行位置坐标标记时需要依赖于场景地图。实际大厦的室内场景地图可能会发生变化，如果场景地图发生变化，则需要在位置服务平台更新大厦地图信息。因此每次使用客户端进行指纹采集时需要对本地图版本进行校验并更新到最新版本。

指纹数据更新模块：每次进行指纹采集的数据首先会存储到本地，用户在当

前场景的指纹采集全部完毕之后可以选择将所有指纹数据打包上传到位置服务平台。但是本地数据可能会存在 3 个问题：1) 由于室内场景变动或信号高动态性导致之前的指纹数据失效；2) 用户采集指纹时错误操作，导致已存储的指纹数据无效；3) 对于复杂大型室内场景，指纹采集需要分批次完成，每次需要先导入已采集的部分数据。针对上述 3 个问题，都需要对本地指纹数据设计更新机制，保证数据有效性。

指纹数据采集模块：该模块是本客户端的核心模块。在实际室内场景中，一般定位区域面积非常大。如果采用传统的按点采集方式，效率很低，极其耗时。因此，本模块设计按直线连续采集的方式进行指纹采集。具体而言，用户可首先选择场景中一条直线路径，采集过程就是匀速从直线的一个端点行走到另一个端点即可。模块在采集期间周期性扫描 BLE 信号，并通过对直线路径坐标插值获得信号样本的标记位置。这种方式能够大大提高位置指纹采集效率，保证系统的实用性。采集流程如图 4.4 所示。

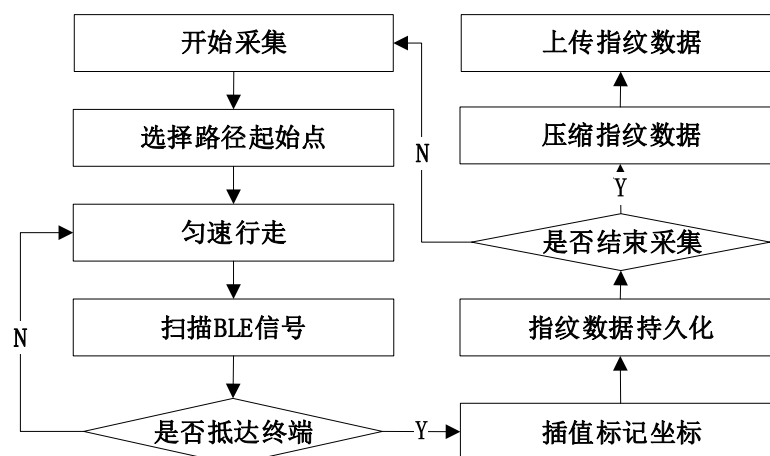


图 4.4 指纹采集流程示意图

Figure 4.4 Diagram of collection process of fingerprint

指纹数据上传模块：当指纹数据采集完毕之后，用户可选择将指纹数据压缩上传到位置服务平台，以供平台进行模型训练。此外，数据上传接口需要验证用户的权限，以保证用户数据的安全性。

4.2.2 位置服务云平台

位置服务云平台是蓝牙定位系统的后台部分，主要功能模块有：指纹数据管

理模块、大厦数据管理模块、用户管理模块、模型训练模块和位置服务 API 模块。如图 4.5 所示。下面将逐一介绍每个模块。

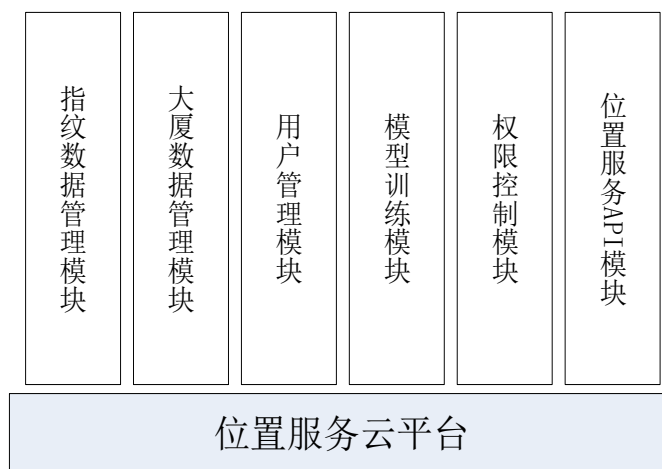


图 4.5 位置服务云平台功能模块示意图

Figure 4.5 Diagram of function modules in LBS cloud platform

指纹数据管理模块：指纹采集客户端上传指纹数据到位置服务平台后，通过指纹数据管理模块对指纹数据进行统一管理，具体内容包括指纹数据存储、更新、删除和查看等。

大厦数据管理模块：对于需要室内位置服务的场景，本模块负责场景信息的注册编辑、场景地图的增删改查以及场景信息统计等功能。

用户管理模块：不同用户有不同的用户信息、用户权限。本模块负责用户的注册登录、账号管理、用户统计等功能。

模型训练模块：本模块对指纹采集客户端上传的指纹数据进行 SOSELM 算法的非增量初始训练，得到初始模型 M 。然后本模块将把原始指纹数据和当前模型 M 进行持久化存储。

权限控制模块：该模块主要用于对指纹采集客户端发起的访问请求进行权限过滤。根据 4.2.1 小节介绍，这里的访问请求包括两种，一个是用户身份登录请求，另一个是用户上传指纹数据时安全验证请求。

位置服务 API 模块：位置服务云平台通过 API 接口对外提供服务，主要 API 有：场景判断接口、模型下载接口、场景地图下载接口、定位结果上传接口等。

4.2.3 在线定位 SDK

为了将室内定位功能从位置服务应用中分离出来，符合“低耦合、高内聚”的程序设计思想，同时更方便第三方开发者在自己的应用中快速方便集成室内定位功能，本课题设计并实现了在线定位 SDK。我们将核心定位算法和相关功能模块封装成 SDK 包，对外提供简单规范的调用接口。SDK 的结构划分如下图 4.6 所示，可分为接口调用层、位置计算层和数据层。

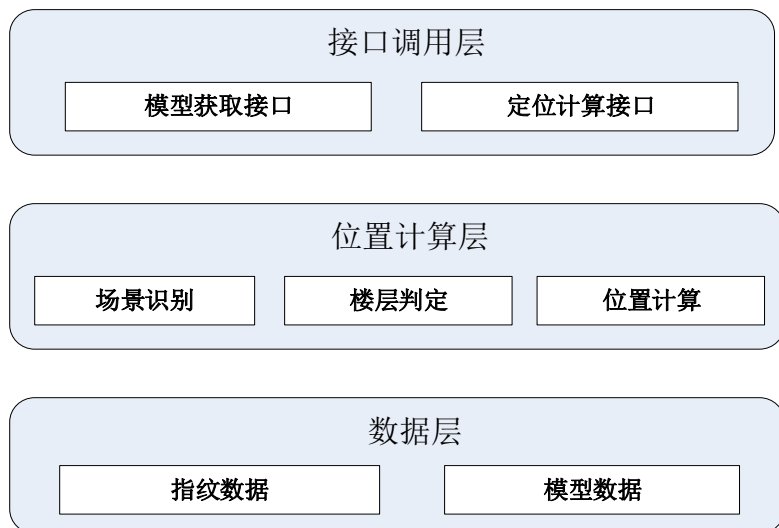


图 4.6 在线定位 SDK 结构图

Figure 4.6 Structure diagram of online localization SDK

接口调用层：SDK 的接口是提供给第三方开发者阅读和调用的，因此需要遵循一些规范性的原则，保证接口精简、高可用、可扩展等。本 SDK 的对外接口主要有两个，一是模型获取接口，SDK 根据该接口从位置服务云平台获取初始模型参数；另一个是定位计算接口，通过调用该接口，上层应用在相应的回调函数中周期性地获得定位终端的实时位置。

位置计算层：位置计算层负责定位计算的主要流程。首先 SDK 需要识别当前的室内场景，以便后续获取该场景的定位模型和地图展示。识别的方式有两种，一种是上层应用通过接口提供当前场景信息；另一种是上层应用不提供场景信息，需要 SDK 使用场景识别模块自动识别当前场景。获取当前场景信息后，SDK 可通过扫描的部分信号特征进而判断当前所处楼层。确定场景和楼层，SDK 就可以获取定位模型，从而进行位置计算。

数据层：在线定位 SDK 主要维护两类数据：指纹数据和模型数据。指纹数

据主要是实时采集的无标记数据，一方面用于位置计算获取定位结果，另一方面还用于模型的实时在线更新，保证模型终端自适应能力。模型数据在首次定位时来源于位置服务云平台，之后随着终端持续进行定位服务，模型数据不断更新，并在本地持久化存储。为了保证模型数据有效性，本地的模型数据会使用过期机制进行管理。

在线定位 SDK 整体工作流程如下图 4.7 所示。

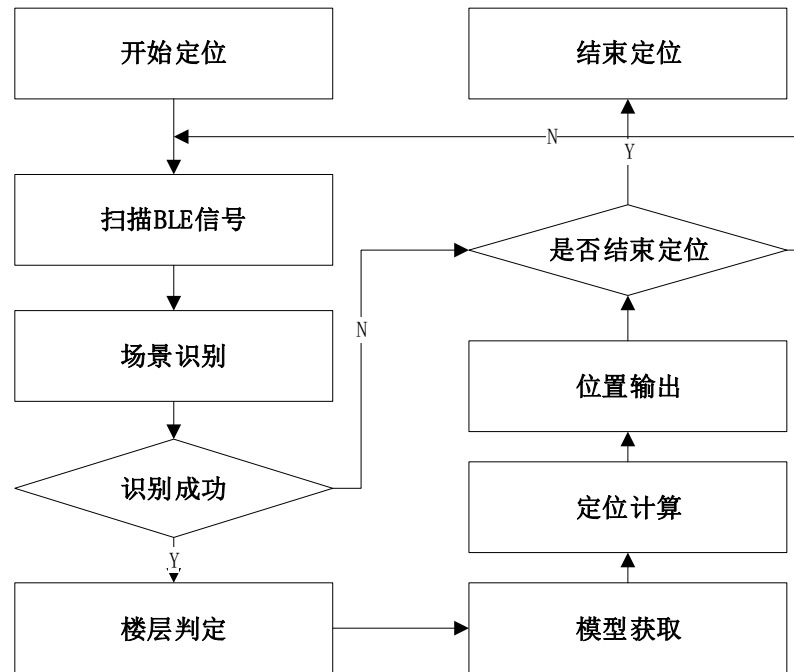


图 4.7 在线定位 SDK 工作流程图

Figure 4.7 Positioning process diagram of online localization SDK

4.3 系统展示

上一小节主要介绍了终端自适应的蓝牙室内定位系统的具体设计，本小节将首先展示开发完成的系统并演示定位效果，然后介绍本蓝牙定位系统的应用案例。

4.3.1 功能演示

为了演示上文所述的定位系统的运行效果，我们接下来将在测试场景进行测试。测试场景长约 20.3 米，宽约 8.04 米。我们将首先使用指纹采集客户端对测试场景进行指纹数据采集演示，然后使用集成了在线定位 SDK 的定位客户端展示定位效果，并在地图上还原终端移动轨迹。

(一) 指纹采集

指纹采集客户端基于 Android 系统开发，支持 Android 5.0 以上系统。测试手机型号为华为荣耀 6。指纹采集工具使用过程如图 4.8 所示。用户首先输入账号信息登录指纹采集客户端，选择测试场景，进入采集界面。然后按照图 4.9 所示的采集路径进行指纹采集。采集完成之后，点击“上传数据”按钮，程序将自动对数据进行压缩打包，并将指纹上传到位置服务云平台。



图 4.8 指纹采集工具界面展示

Figure 4.8 Interface display of fingerprint collection software


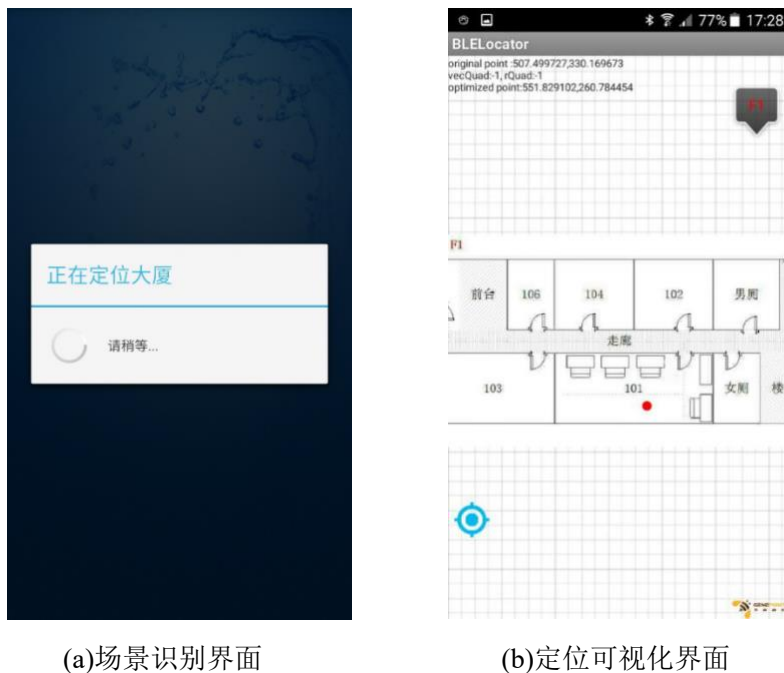


图 4.9 指纹采集路线示意图

Figure 4.9 Diagram of fingerprint collection route

（二）定位演示

指纹数据上传到位置服务平台并经过模型训练之后，接下来进行定位演示。在华为荣耀 6 手机上安装集成了在线定位 SDK 的定位 APP，然后即可以开启定位服务。应用将依次进行场景识别、楼层判断以及位置估算。定位演示如下图 4.10 所示。



(a)场景识别界面

(b)定位可视化界面

图 4.10 蓝牙定位演示图

Figure 4.10 Display of BLE localization

（三）轨迹还原

为了更全面直观地了解系统的定位效果，我们沿着图 4.9 所示的路线行走，然后将所有的定位结果还原到地图上展示，从而得到整个行走的轨迹图。如下图 4.11 所示。可以看出，整体定位效果比较理想，定位精度较高，且定位稳定性较好。




图 4.11 定位轨迹示意图

Figure 4.11 Diagram of localization trajectory

4.3.2 案例展示

本文在第一章就介绍了目前 LBS 应用的蓬勃发展，本章设计并实现的室内定位系统在实际室内场景也有诸多应用。接下来将介绍两个典型的应用案例。

（一）购物中心的室内定位应用案例

在现代综合城市服务概念下，购物中心作为一个重要的载体，人群消费的整体升级让购物中心经营者需要更加关注消费者的体验。室内定位服务应用在购物中心有利于提升消费者的购物体验，同时也有利于加强购物中心数字化建设。室内定位不仅可以提供精准的室内导航服务，还可以与消费者的室内行为大数据进行结合，让数据分析更加精准和细微，实现用户人群画像和商业精准营销。为此，我们将室内定位系统与大型购物中心进行数据结合，实现购物中心一体化的室内位置服务。用户可以借助相应 APP 进行位置导航，找到自己的目标店铺和商品，也可以获取相关商品优惠促销信息等。另外，该系统可以实时跟踪消费者的位置与动向，分析消费者在购物中心的停留位置等行为特征，剖析消费者在不同时间、不同地点的行为关联，从而帮助商家解读消费者的消费习惯和消费需求，并基于此挖掘营销价值，指导商家和购物中心的运营决策，实现购物中心正循环。APP 效果如下图 4.12 所示。



图 4.12 购物中心室内定位应用展示

Figure 4.12 Display of localization application in shopping mall

(二) 大型停车场的室内定位应用案例

近年来,随着人民生活水平的提高,各类机动车数量迅猛增长,如今在火车站、机场、购物中心等大型停车场,停车难和找车难是大多车主十分头疼的问题。一方面,在很多车位紧张的停车场,车主不清楚空闲车位位置,只能四处寻找;另一方面,由于停车场空间大、环境和标志物难以区分,方向不易辨别等原因,车主难以找到自己停放的车辆。为此,我们基于已有的室内定位系统,实现了停车场智能停车服务 APP。用户使用该 APP 可以获悉停车场空余车位的数量和位置,可以标记自己停车的位置并在室内其他任何位置通过 APP 的路径规划功能导航到该停车位置。该智能停车服务能够大大节省用户的停车找车时间,还能提升用户在购物中心等场所的消费体验。APP 效果如下图 4.13 所示。

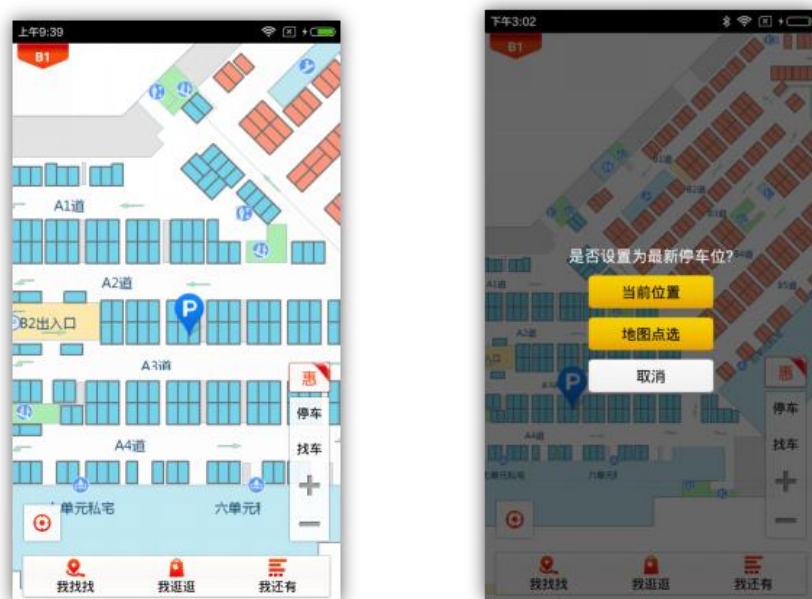


图 4.13 停车场室内定位应用展示

Figure 4.13 Display of localization application in parking lot

4.4 本章小结

本章基于第三章提出的终端自适应在线定位算法设计并实现了 BLE 室内定位系统。该系统主要由指纹采集客户端、位置服务云平台 and 在线定位 SDK 构成。通过在线学习的方式，实现定位模型的自适应更新，有效保证了精准的室内定位精度和良好的定位稳定性。本章首先介绍了系统的架构和运行的流程，然后对系统各模块的具体设计进行了一一介绍，之后在测试场景演示了定位系统的指纹采集过程和定位过程，并对轨迹进行还原展示定位效果，然后又介绍了本系统的两个典型应用场景，最后对本章的系统进行了总结。

第5章 总结与展望

5.1 全文内容总结

随着物联网(Internet of things, IoT)时代的到来,以及各类新型智能移动设备的出现,基于位置感知的应用呈爆发性增长,其中定位技术起到了越来越重要的作用。由于现有的 GPS 等卫星定位技术不适用于高动态性复杂室内场景,人们开始研究各类针对室内场景的定位技术。到目前为止,出现的各类定位技术都有一些应用局限。常见的定位技术如红外定位、超声波定位、UWB 定位、RFID 定位等,或者需要专门的硬件设备,或者部署复杂、定位局限性高,难以进行大规模的推广应用。随着国内大力推进智慧城市、智慧商业环境建设,WiFi 和蓝牙作为智能手机支持的两种基本的无线设备,在国内大多城市广泛普及,给基于 WLAN、蓝牙的低成本室内定位技术提供了丰富的无线信号资源。不论是基于 WLAN 或是低功耗蓝牙的室内定位技术,大部分的应用主要依赖于位置指纹定位算法。位置指纹定位算法具有定位精度较高、适用性广、定位成本较低的优点。但是传统的位置指纹定位算法还存在数据标记难、模型时效性差和设备差异性大等问题。这些问题一方面极大增加了训练阶段的工作量,另一方面严重影响了模型的定位精度,最终制约了位置指纹算法的应用。

针对上述问题,本文基于极速学习机模型提出半监督增量式极速学习机算法。通过半监督学习解决数据标记难问题,通过在线增量式学习方式解决模型时效性问题和设备差异性问题,从而使模型具有终端自适应能力,有效解决上述问题。全文内容总结如下:

本文引言首先介绍了研究的背景和意义,介绍了室外定位技术无法应用于室内环境,从而引出了室内定位技术产生的原因。然后对目前常见的室内定位技术进行了介绍和对比,并阐述了本文研究对象——位置指纹定位方法成为当前主流室内定位方法的原因。之后介绍了位置指纹定位方法中的设备差异性问题 and 研究现状,为本文工作的展开提供了必要性的根据。最后说明了本文的研究重点和贡献,以及全文的组织结构。

此后,本文介绍了目前室内几种经典无线定位技术,在此基础上,详细探讨

了位置指纹定位方法，从方法原理、常见匹配算法和方法的优缺点等多个角度进行了分析和阐述。为了解决目前位置指纹定位方法存在的几个问题，本文随后开始介绍本文在终端自适应在线定位算法上的研究工作。通过介绍机器学习的一些必要性的概念和学习方式，并引入极速学习机理论，为后续算法的介绍提供理论性的铺垫。而后，本文提出了终端自适应的在线定位方法，该方法基于半监督极速学习机和增量式极速学习机。通过对方法的应用进行有效创新，解决了上文提到的位置指纹方法面临的几个问题。

最后，本文设计并实现了基于低功耗蓝牙的室内定位系统，在实际应用场景测试了系统的有效性，

本文的主要研究内容有以下几点：

1) 首先总结归纳目前常见的室内定位技术，并对目前位置指纹定位方法面临的终端差异问题进行了调研和分析，对目前市面上多款手机在信号扫描上差异性进行了实验验证。

2) 提出一种终端自适应的在线定位方法。该方法基于半监督增量式极速学习机算法，终端首先获得初始定位模型，然后在定位服务阶段，可以利用终端自身实时采集的无标记数据进行在线更新，从而有效解决数据标记难问题、模型时效性问题和设备差异性问题。并通过实验验证了该方法的有效性。

3) 设计并实现了一种低功耗蓝牙室内定位系统。该系统包括指纹采集客户端、位置服务云平台 and 在线定位 SDK。用户先在位置服务云平台注册定位场景信息，然后使用指纹采集客户端采集场景指纹，最后在自己应用中集成在线定位 SDK 即可实现室内定位服务。系统测试结果表明本系统具有很好的实用性。

5.2 未来工作展望

相比于传统指纹定位方法，本文提出的方法提升了模型的定位精度和定位稳定性，并减少了标记数据的工作量，实用性较高。但目前还存在一些不足，后续主要从以下几点开展工作：

1) 引入特征自适应的处理机制。实际场景中，终端设备扫描信号基站会出现一些基站扫描不到，或者扫描到新的基站的情况，这会导致定位系统特征维度的变化，从而使训练阶段的指纹特征维度和定位预测阶段的数据特征维度不等长。针对这个问题，下一步工作将研究如何使特征自适应调整，以符合模型自适应更

新的要求。

2) 融合特征增加定位系统稳定性。由于单一传感器信息存在一定局限性,人们开始使用多传感器信息融合的方式提取特征,从而提升定位效果。本文的方法只使用了终端的 WiFi 或蓝牙信息的一种,后续可以将 WiFi、蓝牙以及惯性传感器等信息进行融合,提高定位系统的鲁棒性。

3) 引入特征去差异化机制。目前众多针对设备差异性问题的研究工作表明,离线阶段和在线阶段不同设备导致的 RSSI 的差异可以用线性变化来描述。因此,后续工作可以引入这部分工作,从特征提取阶段进行去差异化处理,进一步降低设备差异性带来的定位影响。

参考文献

- [1]. Location-based services[M]. Elsevier, 2004.
- [2]. 周忠谟. GPS 卫星测量原理与应用[M]. 测绘出版社, 1992.
- [3]. Jakowski N, Heise S, Wehrenpfennig A, et al. GPS/GLONASS-based TEC measurements as a contributor for space weather forecast[J]. Journal of Atmospheric and Solar-Terrestrial Physics, 2002, 64(5-6):729-735.
- [4]. 谢钢. 全球导航卫星系统原理:GPS、格洛纳斯和伽利略系统[M]. 电子工业出版社, 2013.
- [5]. 魏武财. 北斗导航系统与 GPS 的比较[J]. 航海技术, 2003(6):15-16.
- [6]. 李蕾, 于华楠, 姜元清. 浅析蜂窝定位技术及位置服务[J]. 东北电力大学学报, 2003, 23(4):25-28.
- [7]. 邱东晓. 最后的一米[DB/OL]. 诺基亚研究院. 2011.04.19.
- [8]. 冯彦, 韩跃, 段远征,等. 室内地磁定位导航装置:, CN102252675A[P]. 2011.
- [9]. Priyantha N B, Chakraborty A, Balakrishnan H. The Cricket location-support system[C]. International Conference on Mobile Computing and NETWORKING. ACM, 2000:32-43.
- [10]. Ni L M, Liu Y, Lau Y C, et al. LANDMARC: indoor location sensing using active RFID[J]. Wireless Networks, 2004, 10(6):701-710.
- [11]. Lee C, Chang Y, Park G, et al. Indoor positioning system based on incident angles of infrared emitters[C]. Industrial Electronics Society, 2004. IECON 2004. Conference of IEEE. IEEE, 2004:2218-2222 Vol. 3.
- [12]. 王一强, 孙罡. UWB 超宽带技术研究及应用[J]. 通信技术, 2009, 42(3):9-12.
- [13]. Biswas J, Veloso M. Wifi localization and navigation for autonomous indoor mobile robots[C]. Robotics and Automation (ICRA), 2010 IEEE International Conference on. IEEE, 2010: 4379-4384.
- [14]. Feldmann S, Kyamakya K, Zapater A, et al. An Indoor Bluetooth-Based Positioning System: Concept, Implementation and Experimental Evaluation[C]. International Conference on Wireless Networks, Icw'n '03, June 23 - 26, 2003, Las Vegas, Nevada, Usa. DBLP, 2003:109-113.
- [15]. Want R. The active badge location system[J]. Acm Transactions on Information Systems, 1992, 10(1):91-102.
- [16]. Harter A, Hopper A, Steggles P, et al. The anatomy of a context-aware application[J]. Wireless Networks, 2002, 8(2/3): 187-197.
- [17]. Vossiek M, Wiebking L, Gulden P, et al. Wireless local positioning[J]. Microwave Magazine IEEE, 2003, 4(4): 77-86.

- [18].Hightower J, Want R, Borriello G. Spot ON: An indoor 3D location sensing technology based on RF signal strength. UW CSE Technical Report, 2000.
- [19].Bahl P, Padmanabhan V N. RADAR: an in-building RF-based user location and tracking system. Institute of Electrical & Electronics Engineers Inc, 2000, 2:775-784.
- [20].徐景硕, 周胜明, 蒋华君. 惯性导航系统的发展及其关键技术综述[J]. 科技信息, 2009(35):875-876.
- [21].王俊修, 孔斌. 计算机视觉在机器人目标定位中的应用[J]. 微机发展, 2003, 13(12): 7-10.
- [22].丁长河. 三角定位法[J]. 湖北文理学院学报, 2002, 23(3):92-94.
- [23].石鹏, 徐凤燕, 王宗欣. 基于传播损耗模型的最大似然估计室内定位算法[J]. 信号处理, 2005, 21(5):502-504.
- [24].Brunato M, Battiti R. Statistical learning theory for location fingerprinting in wireless LANs[M]. Elsevier Science Publishers B. V. 2005.
- [25].Tao P, Rudys A, Ladd AM, Wallach DS. Wireless LAN location-sensing for security applications. In: Proc. of the 2nd ACM Workshop on Wireless Security (WiSe). San Diego: ACM Press, 2003. 11–20.
- [26].Haeberlen A, Flannery E, Ladd AM, Rudys A, Wallach DS, Kavraki LE. Practical robust localization over large-scale 802.11 wireless networks. In: Proc. of the ACM MOBICOM 2004, the 10th Annual International Conf. on Mobile Computing and Networking. Philadelphia: ACM Press, 2004. 70–84.
- [27].Dong FF, Chen YQ, Liu JF, NingQ, Piao SM. A calibration-free localization solution for handling signal strength variance. In:Hutchison D, Kanade T, Kittler J, Kleinberg JM, eds. Proc. of the Int'l Workshop on Mobile Entity Localization and Tracking in GPS-Less Environments (MELT). Orlando: Springer-Verlag, 2009. 79–90.
- [28].Kjaergaard MB, Munk CV. Hyperbolic location fingerprinting: A calibration-free solution for handling differences in signal strength. In: Proc. of the IEEE Int'l Conf. on Pervasive Computing. Hong Kong: IEEE Press, 2008. 110–116.
- [29].Tsui AW, Chuang YH, Chu HH. Unsupervised learning for solving RSS hardware variance problem in wifi localization. Mobile Networks and Applications, 2009,14(5):677–691.
- [30].Park JG, Curtis D, Teller S, Ledlie J. Implications of device diversity for organic localization. In: Proc. of the INFOCOM 2011.Shanghai: IEEE Press, 2011. 3182–3190.
- [31].Sun Z, Chen Y, Qi J, Liu J. Adaptive localization through transfer learning in indoor wi-fi environment. In: Proc. of the 2008 7th Int'l Conf. on Machine Learning and Applications. San Diego: IEEE Press, 2008. 331–336.
- [32].邓中亮, 余彦培, 徐连明,等. 室内外无线定位与导航[M]. 北京邮电大学出版社, 2013.
- [33].杨铮, 吴陈沭, 刘云浩. 位置计算:无线网络定位与可定位性[M]. 清华大学出版社, 2014.
- [34].梁久祯. 无线定位系统[M]. 电子工业出版社, 2013.
- [35].万群, 郭贤生, 陈章鑫. 室内定位理论、方法和应用[M]. 电子工业出版社, 2012.

- [36]. Wang X, Wang Z, O Dea B. A TOA-based location algorithm reducing the errors due to non-line-of-sight (NLOS) propagation [J]. IEEE Transactions on Vehicular Technology, 2003, 52(1): 112-116.
- [37]. 任丽荣, 肖军. 基于 TOA 的无线传感器网络自定位技术的研究[J]. 信息与控制, 2006, 35(2):280-283.
- [38]. 孙胜, 李辉, 韩崇昭. 基于 TDOA 定位技术的仿真研究[J]. 无线通信技术, 2002, 11(4):40-43.
- [39]. 田静. 超宽带系统中定位技术的研究[D]. 吉林大学, 2007.
- [40]. 王琦. 基于 RSSI 测距的室内定位技术[J]. 电子科技, 2012, 25(6):64-66.
- [41]. Alasiry A H, Ohyama S. Range-based localization with area verification for sparse distributed Wireless Sensor Networks[C]. International Conference on Advanced Computer Science and Information Systems. IEEE, 2013:43-46.
- [42]. Guerrero E, Xiong H G, Gao Q. A range-free localization algorithm for wireless sensor networks based on unmanned aerial vehicles[C]. International Conference on Networked Digital Technologies. IEEE, 2009:267-273.
- [43]. 申静涛. 基于 RSSI 的对数距离路径损耗模型研究[J]. 电子质量, 2013(12):15-17.
- [44]. Keenan J M, Motley A J. Radio coverage in buildings[J]. British Telecom Technology Journal, 1990, 8(1):19-24.
- [45]. Sharma N K. A weighted center of mass based trilateration approach for locating wireless devices in indoor environment[C]. ACM International Workshop on Mobility Management and Wireless Access. ACM, 2006:112-115.
- [46]. Deng Z, Yu Y, Xie Y, et al. Situation and development tendency of indoor positioning[J]. China Communications, 2013, 10(3):42-55.
- [47]. 汤丽, 徐玉滨, 周牧, 等. 基于 K 近邻算法的 WLAN 室内定位技术研究[C]// 2009 国际信息技与应用论坛. 2009.
- [48]. Lin T N, Lin P C. Performance comparison of indoor positioning techniques based on location fingerprinting in wireless networks[C]// International Conference on Wireless Networks, Communications and Mobile Computing. IEEE Xplore, 2005:1569-1574 vol.2.
- [49]. Ito S, Kawaguchi N. Bayesian Based Location Estimation System Using Wireless LAN[C]// IEEE International Conference on Pervasive Computing and Communications Workshops. IEEE Computer Society, 2005:273-278.
- [50]. Lee M, Han D. Voronoi Tessellation Based Interpolation Method for Wi-Fi Radio Map Construction[J]. IEEE Communications Letters, 2012, 16(3):404-407.
- [51]. Fang S H, Lin T N, Lin P C. Location Fingerprinting In A Decorrelated Space[J]. IEEE Transactions on Knowledge & Data Engineering, 2008, 20(5):685-691.
- [52]. 朱明辉, 张会清. 基于 RSSI 的室内测距模型的研究[J]. 传感器与微系统, 2010, 29(8):19-22.

- [53].Alpaydin E. Introduction to Machine Learning[M]. Pitman, 1988.
- [54].Richard A. Johnson, Dean W. Wichern, 约翰逊, 等. 实用多元统计分析(第四版)[M]. 清华大学出版社, 2001.
- [55].Quinlan J R. Induction on decision tree[J]. Machine Learning, 1986, 1(1):81-106.
- [56].Quinlan R. Bagging, boosting, and C4.5[J]. 1996, 1:725-730.
- [57].Gardner M W, Dorling S R. Artificial neural network (Multilayer Perceptron)—A review of applications in atmospheric sciences[J]. Atmospheric Environment, 1998, 32(14).
- [58].Ukil A. Support Vector Machine[J]. Computer Science, 2002, 1(4):1-28.
- [59].Hofmann T. Unsupervised Learning by Probabilistic Latent Semantic Analysis[C]// Machine Learning. 2001:177-196.
- [60].Zhang J, Shan S, Kan M, et al. Coarse-to-Fine Auto-Encoder Networks (CFAN) for Real-Time Face Alignment[C]// European Conference on Computer Vision. Springer, Cham, 2014:1-16.
- [61].Salakhutdinov R, Hinton G. Deep Boltzmann Machines[J]. Journal of Machine Learning Research, 2009, 5(2):1967 - 2006.
- [62].Lee H, Yan L, Pham P, et al. Unsupervised feature learning for audio classification using convolutional deep belief networks[C]// International Conference on Neural Information Processing Systems. Curran Associates Inc. 2009:1096-1104.
- [63].Zhu X. Semi-supervised learning[M]//Encyclopedia of Machine Learning. Springer US, 2011: 892-897.
- [64].Chapelle O, Scholkopf B, Zien A. Semi-supervised learning (chapelle, o. et al., eds.; 2006)[book reviews][J]. IEEE Transactions on Neural Networks, 2009, 20(3): 542-542.
- [65].ZHU X J. Semi — supervised Learning Literature Survey[R].Madison:University of Wisconsin,2008.
- [66].Zhu X. Cross-domain semi-supervised learning using feature formulation[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 2011, 41(6): 1627-1638.
- [67].徐蓉, 姜峰, 姚鸿勋. 流形学习概述[J]. 智能系统学报, 2006, 1(1):44-51.
- [68].Sutton R S. Barto Reinforcement Learning: An Introduction[C]// MIT Press, 1998:216–224.
- [69].Sutton R S. Learning to Predict by the Methods of Temporal Differences[M]. Kluwer Academic Publishers, 1988.
- [70].Cjch W, Dayan P., Q-learning[J]. Machine Learning, 1992, 8(3-4):279-292.
- [71].Rummery G A, Niranjan M. On-Line Q-Learning Using Connectionist Systems[J]. 1994.
- [72].孙大为, 张广艳, 郑纬民. 大数据流式计算:关键技术及系统实例[J]. 软件学报, 2014, 25(4):839-862.
- [73].Rosenblatt F. The perceptron: a probabilistic model for information storage and organization in the brain.[M]// Neurocomputing: foundations of research. MIT Press, 1988:386-408.
- [74].Huang G B, Zhu Q Y, Siew C K. Extreme learning machine: a new learning scheme of feedforward neural networks[C]//Neural Networks, 2004. Proceedings. 2004 IEEE International Joint Conference on. IEEE, 2004, 2: 985-990.

- [75].Huang G B, Zhu Q Y, Siew C K. Extreme learning machine: theory and applications[J]. Neurocomputing, 2006, 70(1): 489-501.
- [76].Huang G B, Chen L, Siew C K. Universal approximation using incremental constructive feedforward networks with random hidden nodes[J]. Neural Networks, IEEE Transactions on, 2006, 17(4): 879-892.
- [77].刘颖超, 张纪元. 梯度下降法[J]. 南京理工大学学报, 1993(2):12-16.
- [78].Rao C R, Mitra S K. Generalized inverse of matrices and its applications[M]. New York: Wiley, 1971.
- [79].D. Serre, Matrices: Theory and Applications, Springer, New York, 2002.
- [80].Liu J, Chen Y, Liu M, et al. SELM: semi-supervised ELM with application in sparse calibrated location estimation[J]. Neurocomputing, 2011, 74(16): 2566-2572.
- [81].Vladimir N. Vapnik, Vapnik, 张学工. 统计学习理论的本质[M]. 清华大学出版社, 2000.
- [82].Belkin M, Matveeva I, Niyogi P. Regularization and semi-supervised learning on large graphs[C]//International Conference on Computational Learning Theory. Springer Berlin Heidelberg, 2004: 624-638.
- [83].Liang N Y, Huang G B, Saratchandran P, et al. A fast and accurate online sequential learning algorithm for feedforward networks.[J]. IEEE Trans Neural Netw, 2006, 17(6):1411-1423.
- [84].Huang G B, Zhou H, Ding X, et al. Extreme learning machine for regression and multiclass classification[J]. IEEE Transactions on Systems Man & Cybernetics Part B Cybernetics A Publication of the IEEE Systems Man & Cybernetics Society, 2012, 42(2):513-529.
- [85].Borwein D, Borwein J M, Leonard I E. Lp Norms and the Sinc Function[J]. American Mathematical Monthly, 2010, 117(6):528-539.

致 谢

记得 2015 年 9 月那个阳光明媚的早晨，我带着行李从家乡合肥来到北京，来到国科大，开启了我三年的研究生学习生涯。转眼之间，三年时光匆匆而逝。回忆过去，有熬夜加班写论文也有团建聚餐玩游戏，有团队一起赶项目也有自己上台做报告，有攻克 bug 的喜悦也有被导师批评的郁闷，有快乐也有烦恼，很庆幸，在这段精彩的旅程中，我能收获这么多。在此，我衷心向那些陪伴过我、帮助过我的老师、朋友和家人表示感谢。

首先，我要感谢我的导师刘军发老师这三年来对我的谆谆教导。从物理学跨专业学习软件工程，是您悉心教导我如何补充基础知识，如何进行科研，如何做人做事，在我倦怠不前时严格激励我，在我迷茫困惑时耐心引导我，在我小有进步时不吝表扬我。您的教导不限于口头言语，您总是能以身作则，给我们带头做榜样。面临困难时，您每晚熬夜加班到最后离开办公室；学习、工作之余，您教导我们要健康享受生活，您督促我们运动，您自己也经常抽出时间参加羽毛球比赛和游泳比赛。在团队学习工作的两年，是我快速进步的两年。在团队中，您充分信任刚入门软件开发的我并让我参与产品模块的开发，教导我成为一名合格的工程师。再次衷心感谢您的教导！

感谢计算所泛在计算研究中心的陈益强研究员。陈老师知识渊博，治学态度严谨，对课题组研究方向运筹帷幄，能经常与学生亲切交流和互动等等特点都让我钦佩不已，并激励我努力前进。在此向陈老师表示由衷地感谢，祝愿陈老师事业上取得更大的成就和突破，在生活中永葆健康，家庭永远幸福美满。

感谢计算所泛在计算研究中心的纪雯老师、彭晓晖老师、潘志文老师、谷洋老师、焦帅老师和邢云冰工程师，是您们组成了泛在计算研究中心的强大技术后盾，为课题组学生排忧解难，解疑答惑，每次跟您们交流都能让我获益匪浅。同时感谢赵雪艳老师和吴萍老师在后勤保障工作中任劳任怨，辛勤付出，为泛在计算中心的正常运转保驾护航。

感谢泛在计算研究中心感知计算研究课题组这个优秀的团队，让我在这之中成长进步。感谢课题组的同学：蒋鑫龙、沈建飞、王晋东、胡春雨、杨晓东、王记伟、李啸海、张迎伟、李梦楠、谢涛、周梦迪、付先凯、沈鸿等同学和已经毕业的何文静、黄美玉、忽丽莎、黄正宇、于汉超等师兄师姐以及其他同学对我的帮助和照顾。和你们在一起学习生活的日子是人生不可多得的美好回忆。

感谢中科劲点的魏总、王总、彭磊、喻双、李鑫斌、李璐，和你们一起肩并肩努力奋斗的日子让我终生难忘。

感谢国科大计算机学院的所有老师和同学，研究生一年级期间，你们在学业和生活中给予了我诸多指导和帮助，让我为以后两年的学习打下了坚实的基础。

感谢室友郭梓超、张红升和曹欢，这么长时间来你们容忍了我许许多多的不良习惯，也给予了我许许多多的帮助，谢谢你们。

由衷感谢我的父母和未婚妻汪晓莎，三年来你们在背后默默支持着我，让我没有后顾之忧。每当我遇到了困难和挫折，每当我垂头丧气时，都是你们在安慰我、鼓励我，使我能勇敢面对困难，完成研究生学业。特别是我未婚妻，在一起五年以来，你一直支持我鼓励我包容我。期待我们幸福的婚礼和爱情的结晶。以后的日子里，我会更加努力，不辜负你们的期望。

最后，对百忙之中抽空评审此论文的老师们的深表谢意！

作者简历及攻读学位期间发表的学术论文与研究成果

作者简历:

2011 年 9 月——2015 年 7 月, 在中国科学技术大学物理学院获得学士学位。

2015 年 9 月——2018 年 6 月, 在中国科学院大学计算机与控制学院攻读工程硕士学位。

已发表(或正式接受)的学术论文:

- 夏俊, 刘军发, 蒋鑫龙, 陈益强. 针对设备差异性问题的增量式室内定位方法[J]. 计算机科学. 【已录用】

参加的研究项目及获奖情况:

- [1] 国家自然科学基金面上项目, “高动态无线环境的渐进式自适应定位方法研究”, 项目编号: No.61173066
- [2] 国家自然科学基金面上项目, “融合多元传播模型和指纹模型的免标定室内定位方法研究”, 项目编号: No.61472399
- [3] 国家自然科学基金青年项目, “基于多目标空间分析的室内无线 AP 布局优化及定位研究”, 项目编号: No.41201410